



Un Enfoque Basado en Principios De Advección-Difusión y Modelos Jerárquicos Bayesianos para la Evaluación de la Sensibilidad en Estimaciones de Cargas Sanitarias y Económicas Atribuibles a la Calidad Del Aire En Bogotá

Juan Manuel Soto Morales
Programa de Ciencia de Datos

Directora: Eddy Herrera Daza
Pontificia Universidad Javeriana
Facultad de Ciencias
Directora Maestría en Matemáticas

Índice

Objetivo General	1
Objetivos Específicos	1
Introducción	1
Marco Teórico	4
1. Contaminación y calidad del aire	4
1.1. Carga Sanitaria y Económica de la contaminación del aire	7
1.2. Series de tiempo en la modelación de contaminantes en la calidad del aire.	8
2. BenMAP-CE como marco metodológico para la evaluación sanitaria y económica	11
2.1. Descripción general	11
2.2. Insumos requeridos para la evaluación sanitaria y económica	12
2.3. Funciones concentración–respuesta e impacto en salud	13
2.4. Valoración económica de los impactos	14
2.5. Alcance y limitaciones de BenMAP-CE en el contexto del estudio	15
3. Modelos Jerárquicos Bayesianos (HBM)	17
3.1. Introducción a los modelos jerárquicos bayesianos	17
3.2. Estructura general de un modelo jerárquico bayesiano	18
3.2.1. Nivel de observación	18
3.2.2. Nivel del proceso latente	19
3.2.3. Nivel de parámetros y distribuciones previas	19
3.3. Condiciones para la aplicación de modelos jerárquicos bayesianos	20

3.3.1.	Dependencia espacial y temporal	20
3.3.2.	Heterogeneidad no observada entre unidades	20
3.3.3.	Datos incompletos o desbalanceados	20
3.3.4.	Necesidad de cuantificar la incertidumbre	21
3.3.5.	Inferencia como objetivo principal	21
3.4.	Aplicaciones de los modelos jerárquicos bayesianos en estudios ambientales y de contaminación del aire	21
3.4.1.	Estimación de contaminantes atmosféricos	21
3.4.2.	Aplicación en redes de monitoreo incompletas	22
3.4.3.	Pronóstico determinista versus pronóstico probabilístico	22
3.5.	Modelos jerárquicos bayesianos espacio–temporales	22
3.5.1.	Dependencia espacial	22
3.5.2.	Dependencia temporal	23
3.5.3.	Interacción espacio–temporal	24
3.6.	Sensibilidad e incertidumbre en modelos jerárquicos bayesianos	24
3.6.1.	Concepto de sensibilidad en modelos jerárquicos bayesianos	24
3.6.2.	Fuentes de incertidumbre	24
3.6.3.	Sensibilidad a las distribuciones previas	25
3.6.4.	Sensibilidad a la estructura espacial y temporal	25
3.6.5.	Evaluación de la sensibilidad	25
3.7.	Rol de los modelos jerárquicos bayesianos en el marco del estudio	26
3.8.	Modelo de balance de masa tipo advección–difusión	27
4.	Metodología	29
4.1.	Enfoque metodológico general	29
4.2.	Fuentes de información y datos utilizados	29
4.3.	Implementación del modelo de balance de masa tipo advección–difusión (A–D)	31
4.3.1.	Dominio, discretización, condiciones operativas y paso temporal del esquema A–D	32
4.3.2.	Interpolación mensual de concentraciones a la malla	35

4.3.3.	Construcción de la estructura de vecindad espacial	36
4.3.4.	Tratamiento de valores faltantes y casos límite	38
4.3.5.	Productos generados en la etapa A–D	39
4.4.	Modelo jerárquico bayesiano espacio–temporal	40
4.4.1.	Caracterización de los observables y justificación estadística del HBM .	41
4.4.2.	Unidad de análisis y dominio espacio–temporal	42
4.4.3.	Construcción de los paneles de modelación	43
4.4.4.	Variables de entrada al modelo	43
4.4.5.	Estructura espacial	45
4.4.6.	Estructura temporal	46
4.4.7.	Métricas de evaluación predictiva	47
4.4.8.	Selección del modelo final por contaminante	49
4.4.9.	Legitimación de los campos espacio–temporales generados	49
4.5.	Módulo computacional de evaluación sanitaria y económica	51
4.5.1.	Construcción de escenarios de exposición	52
4.5.2.	Estimación del cambio en eventos de salud	52
4.5.3.	Funciones concentración–respuesta seleccionadas	53
4.5.4.	Población expuesta y tasas base	53
4.5.5.	Valoración económica en COP de 2015	54
4.5.6.	Agregación espacial y productos de salida	55
4.6.	Análisis de sensibilidad	55
5.	RESULTADOS	58
5.1.	Caracterización inicial del área de estudio y de los campos de concentración . .	58
5.1.1.	Evidencia de autocorrelación espacial global en los campos interpolados	65
5.1.2.	Validación del campo interpolado mediante leave-one-out	66
5.2.	Resultados del componente de advección-difusión	68
5.3.	Resultados del modelo jerárquico bayesiano espacio–temporal	73
5.3.1.	Desempeño predictivo y comportamiento fuera de muestra	74
5.3.2.	Superficies posteriores de concentración	78

5.3.3.	Incertidumbre posterior de las estimaciones	80
5.3.4.	Síntesis de resultados del HBM	81
5.3.5.	Implicaciones de la validez de los modelos ambientales sobre la expo- sición y la valoración económica	82
5.4.	Resultados de la corrida base sanitaria y económica	84
5.4.1.	Resultados agregados por <i>endpoint</i>	84
5.4.2.	Distribución espacial del valor económico por localidad	86
5.5.	Resultados del análisis de sensibilidad	88
5.5.1.	Sensibilidad asociada al escenario derivado del HBM	89
5.5.2.	Sensibilidad asociada a escenarios climáticos	90
5.5.3.	Síntesis de los resultados de sensibilidad	91
6.	DISCUSIÓN	93
6.1.	CONCLUSIONES	95
7.	LIMITACIONES DEL ESTUDIO	98
8.	RECOMENDACIONES Y TRABAJO FUTURO	100
8.1.	ANEXOS	102

Objetivo General

Evaluar la sensibilidad de las estimaciones espacio-temporales de la carga sanitaria y económica atribuible a la contaminación del aire en Bogotá, a partir de un modelo jerárquico bayesiano y de un esquema computacional de evaluación sanitaria y económica basado en BenMAP-CE, considerando distintos escenarios de cambio en la calidad del aire.

Objetivos Específicos

1. Caracterizar la dinámica espacial y temporal de las concentraciones de $PM_{2.5}$, NO_2 y O_3 en Bogotá mediante un modelo de balance de masa tipo advección-difusión.
2. Desarrollar un modelo jerárquico bayesiano espacio-temporal para estimar las superficies de concentración de los contaminantes $PM_{2.5}$, NO_2 y O_3 en Bogotá.
3. implementar un módulo computacional estructurado con base en la lógica de BenMAP-CE, para estimar la carga sanitaria y económica atribuible a la contaminación del aire en Bogotá.
4. Analizar el impacto de las estimaciones sanitarias y económicas ante cambios en las superficies de exposición y ante distintos escenarios de calidad del aire en Bogotá.

Introducción

La contaminación del aire es uno de los principales problemas ambientales y de salud pública a escala global debido a su relación con diferentes enfermedades respiratorias, cardiovasculares y con su incidencia en la mortalidad prematura. En ambientes urbanos, la concentración y la distribución de los contaminantes atmosféricos como el Material particulado fino, dependen de una interacción entre las fuentes de emisión, las condiciones meteorológicas, los procesos de transporte y dispersión, así como de características propias del entorno (Ebi McGregor, 2008). Entre los contaminantes de mayor impacto sanitario se encuentran el material particulado fino $PM_{2.5}$, el dióxido de nitrógeno NO_2 y el ozono troposférico O_3 , cuyos efectos en la salud han sido ampliamente estudiados (Pope & Dockery, 2006; Ebi & McGregor, 2008;

Manisalidis et al., 2020; WHO, 2021).

La Organización Mundial de la Salud (OMS) ha señalado que una parte importante de la población mundial está expuesta a niveles de contaminación superiores a los umbrales guía recomendados, lo que se traduce no solo en una carga sanitaria considerable, sino también en pérdidas económicas relacionadas con la mortalidad, la morbilidad, las hospitalizaciones y la disminución del bienestar social (WHO, 2021; World Bank & IHME, 2016). En este contexto, cuantificar los impactos sanitarios y económicos atribuibles a la contaminación atmosférica resulta importante para priorizar intervenciones y evaluar los beneficios potenciales de mejoras en la calidad del aire (Sacks et al., 2018; EPA, 2024).¹

En ciudades como Bogotá, este problema adquiere una complejidad adicional dado que la variabilidad espacial y temporal de los contaminantes se ve influenciada principalmente por el tráfico vehicular, la actividad industrial, la meteorología local y la distribución desigual de las fuentes de emisión, entre otras. A esto se suma que las redes de monitoreo atmosférico no representan de manera completa la heterogeneidad espacial del fenómeno, lo que introduce incertidumbre al momento de estimar las concentraciones en el espacio. Esta limitación es especialmente relevante en estudios que buscan trasladar estimaciones de concentración a métricas de exposición poblacional e impactos en salud (Rodríguez-Villamizar et al., 2018; González & Pabón, 2019; Ramírez et al., 2013).

Teniendo en cuenta estas limitaciones, los modelos jerárquicos bayesianos (MHB) ofrecen un marco adecuado para integrar diferentes fuentes de información, representar dependencias espaciales y temporales, capturar la heterogeneidad de la información y cuantificar la incertidumbre asociada a las estimaciones. Es por esto que este tipo de modelos son útiles cuando se tiene información incompleta, de cobertura desigual o que tiene una estructura compleja, como ocurre con los contaminantes atmosféricos urbanos (Banerjee et al., 2014; Carvour et al., 2018). En este trabajo, este enfoque se acopla con los principios de advección-difusión, utilizado como un soporte físico para construir variables espaciales y temporales operacionales que fortalezcan la modelación estadística del proceso de contaminación.

¹De acuerdo con las *WHO Global Air Quality Guidelines* actualizadas en 2021, los valores guía estrictos para exposición de largo plazo se encuentran en el siguiente link: [https://www.who.int/es/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/es/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health)

Por otra parte, la evaluación sanitaria y económica en la calidad del aire requiere trabajar con funciones concentración–respuesta, datos de población expuesta, tasas base de incidencia y supuestos de valoración económica como están implementados en el Software BenMAP-CE el cual se toma como un referente metodológico internacional para estructurar análisis de impacto en salud y monetización de beneficios relacionados con mejoras en la calidad del aire (Sacks et al., 2018; EPA, 2024). Sin embargo, estos resultados dependen directamente de la calidad de las superficies de exposición utilizadas como insumo y de los supuestos adoptados para construir escenarios de referencia y de control en el contexto que se realice en el estudio. Adicionalmente, la incertidumbre en la estimación espacio-temporal de contaminantes puede trasladarse de manera sustancial a la carga sanitaria y económica resultante.

Con esto, se busca analizar cómo las decisiones metodológicas y la incertidumbre estadística asociada a la estimación de contaminantes pueden modificar la magnitud de la carga sanitaria y económica atribuible a la calidad del aire.

Marco Teórico

Capítulo 1

Contaminación y calidad del aire

El cambio climático se entiende como una alteración de algún patrón en el ecosistema o en el clima global, siendo esta generada por diferentes efectos naturales o artificiales, específicamente por la producción de gases de efecto invernadero. Según autores como Jacob Winner en 2009, estas transformaciones pueden cambiar diferentes procesos físicos y químicos que influyen en la calidad del aire y que conllevan a un cambio en su comportamiento. Esto se puede observar en eventos como aumentos en la temperatura del ambiente, cambios en la radiación solar e incendios forestales. En este contexto, la mala calidad del aire se convierte en uno de los principales problemas que afectan la salud de las personas. Los contaminantes de la atmósfera no solo se pueden apreciar en actividades como el transporte, las industrias o incluso en la combustión de fósiles, que es uno de los principales contaminantes críticos a nivel global, sino que también estos se ven influenciados por condiciones climáticas extremas, relacionándose con el cambio climático (Ebi McGregor, 2008). De esta manera, los panoramas del cambio climático mencionados anteriormente y muchos más, influyen en el escenario de la mala calidad del aire haciendo que se refleje consecuencias en la salud de las personas como enfermedades respiratorias y cardiovasculares (Tagaris et al., 2010). Esto

demuestra que no solamente puede ser un problema para el ecosistema, sino un gran desafío para toda la gestión ambiental y sanitaria, como es el caso de Bogotá, donde es una ciudad que se puede ver la sobrepoblación a través del tráfico vehicular.

A nivel global, la Organización Mundial de la Salud (OMS) han establecido guías de referencia que fijan un umbral de exposición para los diferentes contaminantes en el aire, entre los que incluyen el material particulado fino (PM.), el dióxido de nitrógeno (NO), el ozono troposférico (O), el dióxido de azufre (SO) y el monóxido de carbono (CO) (WHO, 2021), lo que representa un riesgo a largo plazo para la salud pública, la economía y el ambiente (Ver figura 1.1)

	Promedio anual	Promedio corto plazo
PM _{2.5}	5 µg/m³	15 µg/m³ (24 horas)
NO ₂	10 µg/m³	25 µg/m³ (24 horas)
O ₃	60 µg/m³ (8h)	100 µg/m³ (8 horas)
SO ₂	– (no hay guía anual)	40 µg/m³ (24 horas)
CO	– (no hay guía anual)	4 mg/m³ (24 horas, equivalente a ~3.5 ppm)

estos umbrales no han cambiado hasta este año 2025

Figura 1.1. *Guía de umbrales de calidad del aire según la OMS (2021).*
 Elaboración propia con base en WHO global air quality guidelines: Particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. <https://www.who.int/publications/i/item/9789240034228>

De acuerdo con la OMS en el año 2021, la exposición anual a concentraciones de PM. que sean superiores a 5 µg/m³ y de NO mayores a 10 µg/m³ ya es un riesgo preocupante para la salud en las personas. A pesar de que las guías de los umbrales fueron actualizadas hasta el año 2021 a nivel global y no han hecho ningún cambio hasta el año 2025, no hay algún aviso que mencione que no tendrá consecuencias en la salud pública.

El PM. es el contaminante más dañino ya que no se puede percibir fácilmente y su tamaño es casi inferior a 2.5 micrómetros (μm), lo que le permite estar en el aire durante periodos largos de tiempo y transportarse fácilmente a grandes distancias en la atmósfera y está conformado por diferentes sustancias químicas y sus concentraciones pueden variar dependiendo de la fuente de emisión que la provoca y de las condiciones medioambientales mencionado por Pope Dockery en Health effects of fine particulate air pollution: Lines that connect y con relación a Manisalidis et al. en 2020. Además, el cambio climático no solo puede alterar los patrones de un ecosistema, sino que también influye en como se distribuyen involucrándose en procesos meteorológicos como la dispersión, el transporte y la formación de compuestos en el aire(Jacob Winner, 2009). Adicionalmente, fenómenos atmosféricos producen olas de calor, llevando a que la dispersión del contaminante PM. sea mas lenta.(Ver tabla 1.1).

Siguiendo este enfoque, Los escenarios climáticos proyectados por el Panel Intergubernamental de Cambio Climático (IPCC) hace una recomendación y es que si hay altas emisiones de gases de efecto invernadero, las ciudades en desarrollo como Bogotá pueden enfrentar un aumento en la temperatura teniendo que recurrir a un mayor consumo de energía. Por ejemplo, un mayor consumo de electricidad en las familias va a necesitar una mayor producción energética en la ciudad(González Pabón, 2019).

Cuadro 1.1. *Escenarios climáticos, efecto en contaminantes y consecuencias en la salud.*

Escenarios Climáticos	Efecto en Contaminantes	Consecuencias en la Salud
<i>aumento de la temperatura</i>	ayuda a la formación de ozono (O ₃).	incremento en enfermedades respiratorias y cardiovasculares
<i>olas de calor</i>	aumenta las concentraciones de PM _{2.5} y NO ₂ .	hay mayor exposición a los contaminantes y aumenta el numero de enfermedades respiratorias
<i>disminución de la precipitación</i>	menor “lavado” atmosférico por lo que las partículas de PM _{2.5} son más densas en el ambiente.	hay un mayor riesgo de mortalidad prematura y hospitalizaciones
<i>cambio en el comportamiento del viento</i>	se amplía el área de contaminación.	mayor exposición en áreas alejadas de las fuentes
<i>eventos extremos (incendios forestales)</i>	aumentan emisiones de PM y carbono negro.	incremento en mortalidad por inhalación de humo y partículas Manisalidis et al. (2020), IPCC (2022).

Elaboración propia con base en Fiore et al. (2015), Ebi & McGregor (2008), Tagaris et al. (2010), Jacob & Winner (2009), Manisalidis et al. (2020) e IPCC (2022).

1.1 Carga Sanitaria y Económica de la contaminación del aire

La exposición continua a los contaminantes atmosféricos como el PM. y el NO son los principales factores de riesgo ambiental por su forma de ingresar fácilmente por el sistema respiratorio sin ser detectado a primera vista, esto no solo genera inflamación e irritación en las vías respiratorias, también pueden afectar tanto los pulmones como el sistema cardiovascular, demostrando que hay una relación con infecciones respiratorias, asma, bronquitis crónica, enfermedades isquémicas del corazón y una mayor mortalidad prematura según estudios de (Tagaris et al en 2010). Por otra parte, la contaminación del aire tiene impacto en las cargas económicas por un lado, los costos directos relacionados a los precios de hospitalizaciones , medicamentos, consultas y atención en urgencias, por otro lado, los costos indirectos que suelen referirse a la pérdida económica por parte de la productividad laboral, la ausencia escolar por parte de los jóvenes y niños y la reducción en la calidad de vida de la población aclarada por la OMS.(Ver figura 1.2).

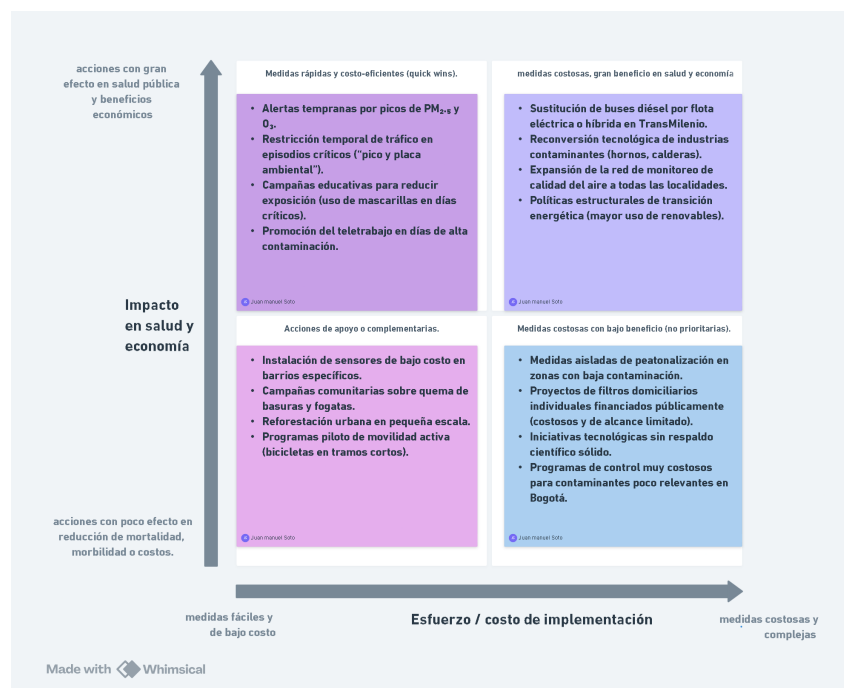


Figura 1.2. *Matriz de impacto–esfuerzo de medidas de calidad del aire en Bogotá*
 Elaboración propia con base en OMS (2021), EPA (2024) y Ramírez et al. (2013). <https://whimsical.com/diagrama-de-impacto-en-salud-y-economia-Ybxwfh46Z8XjwffG7ivK5>

Dado que los impactos sanitarios y económicos están asociados a la evolución espacio-temporal de las concentraciones de los contaminantes, a continuación se aborda el papel de las series de tiempo en la modelación de contaminantes en la calidad del aire.

1.2 Series de tiempo en la modelación de contaminantes en la calidad del aire.

El análisis de series de tiempo ya se vuelve una parte fundamental en la investigación de la calidad del aire, esto nos permite entender cómo cambia los contaminantes a lo largo del tiempo y cómo estos se pueden relacionar con factores de terceros, entre muchas, la actividad humana. Una serie de tiempo en este contexto, se define como una secuencia cronológica para observar el comportamiento de las concentraciones de contaminantes atmosféricos que son registradas en periodos de tiempo (como horarios fijos, diarios o anuales según el contaminante). Su estudio ha sido útil ya que ha beneficiado a la identificación de patrones, fluctuaciones y cambios de tendencias a largo plazo, lo cual es importante para poder construir modelos predictivos y así reducir a un futuro los Impactos en salud y economía (Chatfield, 2004; Banerjee, Carlin Gelfand, 2014). Dentro de los componentes básicos de las series de tiempo se pueden

observar tres elementos clave:

- **Tendencia:** muestra el comportamiento de los datos en periodos largos de tiempo.
- **Estacionalidad:** muestra variaciones que se pueden repetir en intervalos definidos.
- **Variabilidad aleatoria:** corresponde a las diferentes fluctuaciones que se asocian a eventos de los contaminantes (Ebi & McGregor, 2008; Fiore, Naik & Leibensperger, 2015).

Esto es un recurso que ha sido ampliamente usado y la ventaja de este método es que facilita la visualización de los patrones y proporcionan una base preliminar para ajustar los modelos estadísticos más complejos que se aplicarán en este estudio.

Más allá de los elementos clave, el análisis de estos contaminantes necesitan un modelo que sea capaz de reconocer las dependencias de corto plazo y los ciclos estacionales. En este contexto, los **Modelos Autorregresivos Integrados de Medias Móviles Estacionales(SARIMA)**, son una herramienta fundamental que nos permitirá incorporar tendencias y patrones en periodos característicos de aquellos contaminantes(Box, Jenkins Reinsel, 2016; Shumway Stoffer, 2017).

Un modelo general SARIMA (p,d,q)(P,D,Q)_s puede representarse como:

$$\Phi(B^s) \phi(B) (1 - B)^d (1 - B^s)^D y_t = \Theta(B^s) \theta(B) \varepsilon_t \quad (1.1)$$

donde:

- y_t : concentración observada en el tiempo t .
- B : operador de rezago.
- (p, d, q) : órdenes de autorregresión, diferenciación y medias móviles.
- $(P, D, Q)_s$: componentes estacionales con período s (diario, semanal o anual).
- ε_t : término de error aleatorio.

Por esta razón, en este trabajo se considera únicamente como referencia conceptual este método, priorizando en capítulos posteriores un enfoque probabilístico de modelación espacio-temporal mediante Modelos Jerárquicos Bayesianos para la estimación y suavizado de concentraciones de contaminantes atmosféricos en la zona de estudio.

Capítulo 2

BenMAP-CE como marco metodológico para la evaluación sanitaria y económica

2.1 Descripción general

Environmental Benefits Mapping and Analysis Program – Community Edition

(BenMAP-CE) es una herramienta que fue desarrollada por la Agencia de Protección Ambiental de los Estados Unidos (EPA) para estimar los efectos en salud y los beneficios económicos asociados a cambios en la calidad del aire. Su importancia radica en que proporciona una estructura para relacionar variaciones en las concentraciones de contaminantes con cambios esperados en eventos sanitarios, tales como la mortalidad prematura, hospitalizaciones, entre otros eventos, para después traducir esos cambios en métricas económicas comparables entre escenarios de exposición (Sacks et al., 2018; EPA, 2024).

El principio general de BenMAP-CE consiste en comparar dos escenarios de calidad del aire definidos sobre la misma unidad espacial. El primero corresponde al escenario de referencia o *baseline* que representa las condiciones observadas o esperadas en ausencia de una intervención. El segundo corresponde al escenario de control o *control* que representa una condición alternativa de calidad del aire bajo una reducción, regulación o cambio de concentración. A partir de la diferencia entre ambos escenarios, empieza a estimar el cambio en la exposición poblacional y lo traduce en una variación esperada de eventos en salud utilizando funciones concentración–respuesta (EPA, 2024; USEPA, 2023).

2.2 Insumos requeridos para la evaluación sanitaria y económica

Para la evaluación sanitaria y económica de los cambios en la calidad del aire se requiere información consistente entre sí en términos espaciales, temporales y epidemiológicos. Esta articulación se organiza a partir de superficies de concentración de contaminantes, datos de población expuesta, tasas base de incidencia o mortalidad, funciones concentración–respuesta y parámetros de valoración económica, ya que esta estructura permite trasladar un cambio en la exposición ambiental hacia una estimación de casos atribuibles o evitados y, posteriormente, a una cuantificación económica de dichos efectos (Sacks et al., 2018; EPA, 2024; USEPA, 2023).

Cuadro 2.1. *Resumen de los insumos requeridos para una evaluación sanitaria y económica estructurada con base en BenMAP-CE.*

Insumo	Función dentro del análisis
Superficies de concentración	Representa la exposición ambiental bajo escenarios de referencia y control, permitiendo calcular el cambio en concentración entre condiciones comparables.
Población expuesta	Cuantifica el número de personas potencialmente afectadas por los cambios en la calidad del aire dentro de cada unidad espacial.
Tasas base de incidencia	Permiten convertir cambios relativos en riesgo en un número esperado de casos atribuibles o evitados.
Funciones concentración–respuesta	Relacionan el cambio en concentración del contaminante con un cambio esperado en eventos de salud.
Valoración económica	Asigna un valor monetario a los efectos sanitarios estimados para expresarlo en beneficios o cargas en términos económicos.

Elaboración propia con base en Sacks et al. (2018), EPA (2024) y USEPA (2023).

Por esta razón, en el contexto del presente trabajo se adoptó la lógica estructural de BenMAP-CE como guía para organizar estos componentes, manteniendo compatibilidad conceptual con el programa, pero adaptando la implementación a un flujo computacional coherente con la modelación desarrollada en el estudio.

2.3 Funciones concentración–respuesta e impacto en salud

Las funciones concentración–respuesta son el vínculo central entre los cambios en la calidad del aire y los cambios esperados en los eventos de salud. Su función dentro de la evaluación sanitaria consiste en traducir una variación en la concentración de un contaminante en una variación esperada del riesgo de mortalidad o morbilidad en una población expuesta. Estas funciones permiten pasar de una superficie de exposición ambiental a una cuantificación de efectos atribuibles o evitados por lo que representan uno de los componentes más sensibles de todo el análisis. En el marco de BenMAP-CE, estas funciones no se entienden como ecuaciones aisladas, sino como parte de una estructura integrada en la que el cambio en exposición se combina con la población expuesta y con la tasa base de incidencia del evento de salud para obtener una estimación final de impacto (Sacks et al., 2018; EPA, 2024; USEPA, 2023).

La formulación más utilizada en este tipo de estudios es de carácter log–lineal ya que esta estructura supone que un cambio en la concentración del contaminante modifica de forma monótonica el riesgo relativo del evento sanitario, de manera que la exposición adicional se traduce en un aumento esperado del riesgo, mientras que una reducción en la exposición se traduce en un beneficio sanitario esperado. Bajo este supuesto, el cambio en el número de casos puede expresarse como:

$$\Delta Y = Y_0 \left(e^{\beta \Delta C} - 1 \right) \times Pop, \quad (2.1)$$

donde ΔY representa el número esperado de casos atribuibles o evitados, Y_0 corresponde a la tasa base de incidencia o mortalidad del evento de salud, β es el coeficiente concentración–respuesta derivado de la literatura epidemiológica, ΔC es el cambio en la concentración del contaminante entre el escenario de referencia y el escenario de control, y Pop representa la población expuesta en la unidad espacial correspondiente.

Una forma equivalente de representar esta relación consiste en partir del riesgo relativo asociado a un cambio en concentración. Bajo un modelo log–lineal, el riesgo relativo puede escribirse como

$$RR = e^{\beta \Delta C}, \quad (2.2)$$

de modo que el cambio esperado en salud depende de cuánto se aleja este riesgo relativo de la unidad. Si $RR > 1$, la exposición incrementa el riesgo del evento; si $RR < 1$, la modificación del escenario implica una reducción del riesgo; y si $RR = 1$, no se esperaría cambio atribuible bajo la función considerada. Esta representación es útil porque deja explícito que el parámetro β resume la sensibilidad del evento sanitario frente al contaminante. (Banerjee et al., 2014; Sacks et al., 2018; EPA, 2024).

2.4 Valoración económica de los impactos

Una vez ya sean estimados los efectos sanitarios atribuibles o evitados ante cambios en la calidad del aire, la siguiente etapa consiste en asignarles un valor monetario. Para esta fase permite expresar los resultados en una unidad común que facilita la comparación entre escenarios, la interpretación de beneficios potenciales y la discusión sobre intervenciones de política pública. Sin embargo, la monetización de los impactos no debe entenderse como una simple conversión aritmética posterior al cálculo sanitario, sino como una dimensión metodológica propia ya que introduce supuestos económicos adicionales que pueden modificar de forma sustancial la magnitud final de los resultados. Por esta razón, la valoración económica constituye también una fuente relevante de sensibilidad dentro del análisis de impacto en salud ambiental (Sacks et al., 2018; EPA, 2024).

De forma general, la monetización de los efectos puede representarse como:

$$B = \Delta Y \times V, \quad (2.3)$$

donde B corresponde al beneficio o carga económica total asociada al cambio en salud, ΔY representa el número esperado de casos atribuibles o evitados estimado previamente, y V es el valor monetario unitario asignado a cada caso. Aunque esta formulación es conceptualmente sencilla, su aplicación depende de la naturaleza del endpoint sanitario analizado.

En el caso de la mortalidad, el enfoque de referencia corresponde al *Value of a Sta-*

tistical Life (VSL). Este concepto representa la disposición agregada a pagar por pequeñas reducciones en el riesgo de morir. Su importancia radica en que permite monetizar beneficios asociados a disminuciones del riesgo de mortalidad prematura bajo una lógica consistente con la economía del bienestar (EPA, 2024; Sacks et al., 2018).

Para los eventos no fatales, como hospitalizaciones y algunos efectos de morbilidad, la valoración se aproxima mediante esquemas de *Cost of Illness* (COI). Este enfoque recoge principalmente costos directos e indirectos asociados al episodio de enfermedad, tales como gastos médicos, uso de servicios de salud, pérdidas de productividad entre otros. En consecuencia, su alcance es más restringido que el del VSL, ya que no incorpora plenamente componentes como el dolor o el sufrimiento evitado (EPA, 2024; World Bank & IHME, 2016).

Esta diferenciación es importante porque evita interpretar de la misma manera resultados monetarios que provienen de endpoints de naturaleza distinta. En otras palabras, los beneficios económicos asociados a mortalidad evitada no son directamente comparables con los derivados de hospitalizaciones evitadas, ya que responden a fundamentos económicos diferentes.

Finalmente, la valoración económica se incorpora como una dimensión del análisis de sensibilidad ya que implica que los resultados monetarios no se interpretan como cifras únicas y definitivas, sino como aproximaciones condicionadas por supuestos explícitos sobre funciones de valoración, año base monetario y transferibilidad de parámetros.

2.5 Alcance y limitaciones de BenMAP-CE en el contexto del estudio

BenMAP-CE tiene una estructura metodológica sólida para integrar exposición, población, incidencia, funciones concentración–respuesta y valoración económica dentro de un mismo marco analítico y principal fortaleza radica en que permite organizar de manera consistente la evaluación de impactos sanitarios y económicos asociados a cambios en la calidad del aire.

Sin embargo, el alcance de BenMAP-CE depende directamente de la calidad y coherencia de los insumos que recibe. El programa no genera por sí mismo las concentraciones

de contaminantes, sino que requiere superficies de exposición previamente construidas. Por este motivo, la validez de los resultados sanitarios y económicos dependen de la robustez del proceso de modelación ambiental que antecede a la etapa de evaluación.

Otra limitación importante se relaciona con la selección de funciones concentración–respuesta y de parámetros de valoración económica. Aunque BenMAP-CE otorga una estructura clara para integrar estos componentes, no resuelve por sí mismo la pregunta de cuáles funciones son las más apropiadas para el contexto local ni elimina la necesidad de examinar la transferibilidad de los parámetros epidemiológicos y económicos utilizados. Por esto, la incertidumbre asociada a las funciones concentración–respuesta, a las incidencias base y a los valores monetarios unitarios puede trasladarse de manera directa a la magnitud final de la carga sanitaria y económica estimada.

Para el contexto de esta investigación, BenMAP-CE no se emplea como un entorno cerrado de ejecución, sino como un referente metodológico para estructurar la fase final de evaluación sanitaria y económica. Esta decisión responde a que las superficies de exposición fueron generadas externamente y que la implementación final se desarrolló en el lenguaje de programación Python con el fin de mantener coherencia con el flujo real de modelación adoptado en el estudio.

Capítulo 3

Modelos Jerárquicos Bayesianos (HBM)

3.1 Introducción a los modelos jerárquicos bayesianos

Los modelos jerárquicos bayesianos (Hierarchical Bayesian Models, HBM) abarcan un grupo de modelos probabilísticos que están diseñados para representar diferentes procesos complejos mediante una estructura multinivel, es decir, los HBM nos permiten modelar de forma simultánea la variabilidad observacional, la estructura subyacente del proceso de interés y la incertidumbre referente a los parámetros del modelo (Banerjee, 2014).

Desde este enfoque, toda la inferencia estadística se fundamenta en la actualización de distribuciones de probabilidad a partir de la información disponible que se obtenga. En este contexto, los HBM incorporan distribuciones previas sobre los parámetros y procesos latentes, lo que permite integrar información externa, regularizar las estimaciones del caso y cuantificar específicamente la incertidumbre en cada nivel del modelo (Carvour, 2018). Esta característica es fundamental en las aplicaciones ambientales, donde generalmente se pueden apreciar datos incompletos, ruidosos o desbalanceados tanto espacialmente como temporalmente.

Una de las principales fortalezas que tiene los modelos jerárquicos bayesianos es la capacidad para representar dependencias estructurales que son complejas, tales como la correlación espacial entre unidades geográficas o la dependencia temporal entre observaciones sucesivas en los datos. Por parte de los efectos latentes que introducen, los HBM también pueden capturar patrones no observados directamente en los datos, facilitando el suaviza-

miento de las estimaciones, mediante el cual la información de las áreas o periodos vecinos contribuyen a mejorar la estimación en zonas que tenga una menor disponibilidad de datos (Banerjee,2014).

En estudios, los HBM han demostrado ser muy útiles y adecuados para la estimación de concentraciones de contaminantes atmosféricos en áreas urbanas, donde las estaciones de monitoreo tiene una cobertura espacial desigual y las series temporales presentan valores vacíos o discrepancias (Imam, 2024).

3.2 Estructura general de un modelo jerárquico bayesiano

De manera general, un modelo jerárquico bayesiano se compone de tres niveles fundamentales: (i)el nivel de observación, (ii)el nivel del proceso latente y (iii)el nivel de los parámetros. A continuación, se describen estos niveles desde un enfoque mas teórico.

3.2.1 Nivel de observación

El nivel de observación describe la relación entre los datos observados y el proceso que se desea modelar. En este nivel se debe especificar una distribución de probabilidad condicional que caracteriza la variabilidad de las observaciones, condicionada al proceso latente (Gelman, 2013).

Sea $Y_{i,t}$ la observación correspondiente a la unidad i en el tiempo t . De forma general, este nivel puede expresarse como:

$$Y_{i,t} \mid \mu_{i,t}, \theta \sim f(\mu_{i,t}, \theta), \quad (3.1)$$

donde $\mu_{i,t}$ representa la media o intensidad del proceso latente y θ denota un conjunto de parámetros que estan asociados a la variabilidad observacional. Adicionalmente, La elección de la distribución $f(\cdot)$ depende de la naturaleza de la variable analizada.

Este nivel separar el ruido inherente a las mediciones del comportamiento estructural del caso de estudio, permitiendo incorporar errores de medición y fluctuaciones aleatorias de manera explícita (Cressie, 2011).

3.2.2 Nivel del proceso latente

Este componente es el núcleo del modelo jerárquico bayesiano. Representa la estructura subyacente que manjerna la parte de la variabilidad, incorporando dependencias espaciales, temporales o espacio–temporales que no son observables a simple vista (Banerjee, 2014).

De forma general, el proceso latente se representarse como:

$$\mu_{i,t} = \alpha + \mathbf{x}_{i,t}^\top \boldsymbol{\beta} + \phi_i + \delta_t, \quad (3.2)$$

donde α es un intercepto global, $\mathbf{x}_{i,t}$ es un vector de covariables explicativas, $\boldsymbol{\beta}$ es el vector de coeficientes asociados, ϕ_i representa el efecto específico de la unidad espacial i y δ_t el efecto temporal común a todas las unidades.

Al incluir estos efectos latentes, permite capturar heterogeneidad no observada, suavizar las estimaciones y aprovechar la información compartida entre unidades espaciales o periodos temporales (Cressie, 2011; Banerjee, 2014).

3.2.3 Nivel de parámetros y distribuciones previas

Para este componente, el nivel de parámetros completa la especificación del modelo mediante la asignación de distribuciones previas a los parámetros y componentes del proceso latente. Estas distribuciones muestran el conocimiento previo sobre el comportamiento de los parámetros permitiendo regularizar la inferencia estadística (Gelman, 2013; Carvour, 2018).

De manera general, este nivel puede expresarse como:

$$\boldsymbol{\beta} \sim \pi(\boldsymbol{\beta}), \quad \phi_i \sim \pi(\phi), \quad \delta_t \sim \pi(\delta), \quad \theta \sim \pi(\theta), \quad (3.3)$$

donde $\pi(\cdot)$ denota las distribuciones previas asignadas a cada componente del modelo. La combinación de los niveles de observación, proceso latente y parámetros mediante el teorema de Bayes conduce a la distribución posterior conjunta (Gelman, 2013)

En conjunto, esta estructura jerárquica ofrece un marco flexible para el análisis de procesos complejos, permitiendo integrar la información heterogénea, modelar dependencias

estructurales y cuantificar la incertidumbre asociada a las estimaciones.

3.3 Condiciones para la aplicación de modelos jerárquicos bayesianos

3.3.1 Dependencia espacial y temporal

Una de las principales condiciones para el uso de modelos jerárquicos bayesianos es la presencia de dependencia espacial y/o temporal entre las observaciones. En casos ambientales, las mediciones realizadas en unidades geográficas que son cercanas suelen tener comportamientos similares, mientras que las observaciones en instantes temporales consecutivos tienden a presentar autocorrelación (Cressie, 2011).

Los HBM permiten integrar estas dependencias de manera explícita a través de procesos latentes espaciales y temporales para así evitar suposiciones de independencia entre observaciones que pueden conducir a resultados sesgados.

3.3.2 Heterogeneidad no observada entre unidades

Otra condición que es importante para aplicar los HBM es la presencia de heterogeneidad no observada entre datos espaciales o temporales. En muchos contextos de estudios reales, la parte de la variabilidad del fenómeno de interés no se puede explicar únicamente mediante covariables observadas a causa de la falta de información o de factores que no fueron medidos (Banerjee, 2014).

Al introducir estos efectos aleatorios en los HBM permite captar esta heterogeneidad de forma flexible, mejorando la capacidad explicativa del modelo y proporcionando mejores resultados de estimaciones más estables y coherentes.

3.3.3 Datos incompletos o desbalanceados

Los HBM son bastante útiles cuando los datos tienen valores faltantes, cobertura intermitente o estructuras desbalanceadas entre las unidades y los periodos (Carvour, 2018).

Gracias a la formulación probabilística que tiene, los HBM permiten integrar la incertidumbre asociada a la ausencia de información y así aprovechar la información disponible en unidades relacionadas mediante el mecanismo de *borrow strength*.

3.3.4 Necesidad de cuantificar la incertidumbre

En estudios que están alineados a la toma de decisiones, como la evaluación de impactos en salud o el diseño de políticas ambientales, resulta importante no solo obtener estimaciones puntuales, sino también cuantificar la incertidumbre con respecto a dichas estimaciones (Saltelli, 2008).

3.3.5 Inferencia como objetivo principal

Finalmente, el uso de los HBM es sumamente relevante en contextos donde el objetivo principal es la inferencia y la comprensión del fenómeno subyacente, más que una predicción puntual de corto plazo. En estos escenarios, los HBM permiten evaluar el efecto de diferentes supuestos estructurales, analizar la sensibilidad de los resultados y generar inferencias robustas bajo incertidumbre (Gelman, 2013).

3.4 Aplicaciones de los modelos jerárquicos bayesianos en estudios ambientales y de contaminación del aire

3.4.1 Estimación de contaminantes atmosféricos

De acuerdo con Jacob(2009) y Fiore(2015), En el ámbito de la calidad del aire, se han aplicado los HBM para modelar contaminantes como el material particulado fino ($PM_{2.5}$), el dióxido de nitrógeno (NO_2) y el ozono troposférico (O_3). Estos contaminantes tiene una variabilidad espacio-temporal significativa y son medidos por redes de monitoreo con una cobertura espacial desigual, dificultando la estimación precisa mediante enfoques tradicionales.

Los HBM permiten integrar información de múltiples estaciones de monitoreo y periodos temporales, generando estimaciones suavizadas de las concentraciones donde se pueden reflejar tanto la estructura espacial como la evolución temporal del fenómeno. De lo anterior, resulta útil los HBM para hacer interpolación espacial y estimación de concentraciones en áreas donde no hay estaciones de monitoreo fijas(Banerjee, 2014).

3.4.2 Aplicación en redes de monitoreo incompletas

Una de las ventajas al implementar los modelos jerárquicos bayesianos es su capacidad para operar de manera eficiente en contextos donde las redes de monitoreo tienen datos faltantes o cobertura irregular. Al introducir efectos latentes espaciales y temporales, los HBM aprovechan la información disponible en unidades relacionadas para mejorar la estimación en zonas con escasa información y así reducir el sesgo y la varianza de las estimaciones (Cressie, 2011; Imam, 2024).

3.4.3 Pronóstico determinista versus pronóstico probabilístico

Una diferencia clave entre los enfoques tradicionales y los modelos jerárquicos bayesianos es la forma en que se conceptualiza el pronóstico. Por un lado, los métodos deterministas suelen proporcionar un único valor esperado, por el otro lado, los HBM generan distribuciones completas que reflejan esa incertidumbre inherente al proceso modelado (Gelman, 2013).

El pronóstico probabilístico permite evaluar la probabilidad de que las concentraciones de contaminantes superen ciertos umbrales, así como analizar la sensibilidad de estos resultados frente a distintos supuestos del modelo.

3.5 Modelos jerárquicos bayesianos espacio–temporales

Los modelos jerárquicos bayesianos espacio–temporales tomando de referencia Autores como Banerjee,(2014),Cressie,(2011) y Gelman,(2013) son una extensión de los HBM cuando la unidad de interés presenta una dependencia tanto en el espacio como en el tiempo. En este tipo de modelos, la variabilidad observada se explica mediante la combinación de componentes espaciales y temporales para así capturar patrones estructurados y no observados de manera coherente.

3.5.1 Dependencia espacial

La dependencia espacial se refiere a la similitud que tienden a presentar las observaciones que corresponden a unidades geográficas cercanas. Para el contexto de los HBM, esta

dependencia se usa habitualmente mediante efectos aleatorios espaciales definidos a partir de estructuras de vecinos cercanos.

Una de las formulaciones más utilizadas corresponde a los modelos autorregresivos condicionales (Conditional Autoregressive Models, CAR), en donde el efecto espacial asociado a una unidad geográfica se modela de forma condicional a los efectos de sus unidades que son cercanas. De manera general, este tipo de estructura puede representarse como:

$$\phi_i \mid \phi_{-i}, \tau_\phi \sim \mathcal{N}\left(\frac{1}{n_i} \sum_{j \sim i} \phi_j, \frac{1}{n_i \tau_\phi}\right), \quad (3.4)$$

donde ϕ_i representa el efecto espacial de la unidad i , $j \sim i$ es el conjunto de unidades vecinas, n_i es el número de vecinos y τ_ϕ es un parámetro de precisión asociado al componente espacial. Adicionalmente, una variante de este modelo es el modelo autorregresivo condicional intrínseco (ICAR), donde incorpora restricciones adicionales para asegurar la identificabilidad del modelo.

3.5.2 Dependencia temporal

La dependencia temporal describe la relación que existe entre observaciones que corresponden a instantes consecutivos en el tiempo. En los HBM, se representa mediante procesos estocásticos que modelan la evolución temporal del efecto latente.

Entre las formulaciones más conocidas se encuentran los procesos autorregresivos de primer orden (AR(1)) y las caminatas aleatorias de primer orden (Random Walk de orden 1, RW(1)). El modelo AR(1) asume que el efecto temporal en un instante va a depender linealmente del efecto en el instante anterior, mientras que el modelo RW(1) representa una evolución más flexible basada en incrementos sucesivos:

$$\text{AR(1): } \delta_t = \rho \delta_{t-1} + \epsilon_t, \quad (3.5)$$

$$\text{RW(1): } \delta_t = \delta_{t-1} + \epsilon_t, \quad (3.6)$$

donde ρ es un parámetro de autocorrelación temporal y ϵ_t representa un término de error aleatorio.

Desde un punto de vista teórico, Los modelos AR(1) son útiles para representar dependencias temporales de corto alcance, mientras que los modelos RW(1) permiten capturar tendencias suaves y cambios graduales en el tiempo, siendo utilizados en gran parte por estudios ambientales con datos agregados temporalmente.

3.5.3 Interacción espacio–temporal

En algunos contextos, la variabilidad del fenómeno de interés no puede explicarse solamente por la suma de componentes espaciales y temporales independientes. En estos casos, los HBM pueden extenderse para incorporar términos de interacción espacio–temporal ya que permiten capturar dinámicas específicas de ciertas regiones a lo largo del tiempo.

No obstante, la incluir las interacciones espacio–temporales incrementa la complejidad del modelo y se necesita un balance cuidadoso entre flexibilidad y estabilidad, especialmente cuando los datos presentan limitaciones en cobertura espacial o temporal.

3.6 Sensibilidad e incertidumbre en modelos jerárquicos bayesianos

3.6.1 Concepto de sensibilidad en modelos jerárquicos bayesianos

En el contexto bayesiano, la sensibilidad hace referencia al grado en que las distribuciones posteriores de los parámetros y del proceso latente varíen ante cambios en los supuestos del modelo. Estos cambios pueden estar relacionados a la especificación de las distribuciones previas, la estructura de dependencia espacial y temporal, o la inclusión y parametrización de covariables (Saltelli, 2008)

3.6.2 Fuentes de incertidumbre

La incertidumbre en los modelos jerárquicos bayesianos surgen por varios motivos, entre las cuales se destacan: la variabilidad observacional inherente a los datos, la incertidumbre asociada al proceso latente no observado y la incertidumbre paramétrica derivada de la estimación de los parámetros del modelo (Gelman, 2013).

3.6.3 Sensibilidad a las distribuciones previas

Una de las principales fuentes de sensibilidad en los HBM corresponde a la especificación de las distribuciones previas. Diferentes elecciones de priors, ya sean porque tienen información muy débil o muy concreta, pueden influir en los resultados y dispersión de las distribuciones posteriores (Gelman, 2013).

3.6.4 Sensibilidad a la estructura espacial y temporal

la estructura espacial y temporal del proceso latente también es otra fuente relevante de sensibilidad en los modelos jerárquicos bayesianos ya que la elección de diferentes fórmulas para representar la dependencia espacial o temporal puede generar variaciones en las estimaciones. (Banerjee, 2014; Cressie, 2011).

3.6.5 Evaluación de la sensibilidad

La evaluación de la sensibilidad en los HBM se procede mediante la comparación de distribuciones posteriores obtenidas bajo diferentes supuestos del modelo. Esta comparación puede analizarse a través de intervalos creíbles (IC), medidas de dispersión posterior y criterios de ajuste global para así identificar cambios sustantivos en los resultados. (Ver tabla 3.1)

Cuadro 3.1. Métricas de evaluación y validación en modelos jerárquicos bayesianos

Métrica	Uso en modelos HBM	Interpretación
Intervalos creíbles	Cuantificación de la incertidumbre asociada a parámetros y procesos latentes	Indican el rango de valores plausibles de un parámetro dado el modelo y los datos, permitiendo evaluar la precisión y estabilidad de las estimaciones.
Distribución posterior	Análisis completo de la inferencia bayesiana	Permite examinar la forma, dispersión y posibles asimetrías de los parámetros estimados, reflejando la incertidumbre total del modelo.
DIC (Deviance Information Criterion)	Comparación entre modelos con distinta complejidad	Evalúa el balance entre ajuste del modelo y complejidad; valores menores indican un mejor compromiso entre ambos.
WAIC (Watanabe–Akaike Information Criterion)	Evaluación de capacidad predictiva del modelo	Aproxima la validación cruzada bayesiana a partir de la verosimilitud puntual; valores más bajos sugieren mejor desempeño predictivo.
LOO-CV (Leave-One-Out Cross-Validation)	Validación cruzada y robustez del modelo	Analiza la estabilidad del modelo frente a la exclusión de observaciones individuales, permitiendo detectar sensibilidad a datos influyentes.
Análisis de residuos posteriores	Diagnóstico de deficiencias estructurales	Permite identificar patrones espaciales o temporales no capturados por el modelo, indicando posibles problemas de especificación.

Elaboración propia con base en Gelman et al. (2013), Banerjee et al. (2014), Cressie y Wikle (2011).

3.7 Rol de los modelos jerárquicos bayesianos en el marco del estudio

En el contexto del presente trabajo, los modelos jerárquicos bayesianos tienen un rol fundamental como herramienta estadística para la estimación espacio–temporal de las concentraciones de contaminantes atmosféricos. Su formulación tiene la intención de incorporar información proveniente de diferentes fuentes, capturar dependencias espaciales y temporales, y cuantificar de manera explícita la incertidumbre asociada a las estimaciones.

Los HBM se emplean específicamente para caracterizar la variabilidad espacio–temporal de los contaminantes del aire bajo distintos supuestos estructurales, proporcionando estimaciones suavizadas y coherentes que sirven como un insumo para análisis posteriores.

En este sentido, estos modelos no tienen como objetivo directo la estimación de impactos en salud, sino la generación de concentraciones representativas y consistentes desde un punto de vista estadístico.

Las estimaciones obtenidas mediante los modelos jerárquicos bayesianos alimentan la herramienta BenMAP-CE, la cual se encarga de cuantificar la carga sanitaria y económica atribuible a la contaminación del aire. De esta forma, los HBM son un componente intermedio entre la modelación de la calidad del aire y la evaluación de impactos en salud pública, permitiendo analizar cómo la incertidumbre y la sensibilidad en las concentraciones estimadas se propagan hacia los resultados sanitarios y económicos.

3.8 Modelo de balance de masa tipo advección–difusión

El cambio espacio temporal de las concentraciones de contaminantes atmosféricos puede describirse como el principio de conservación de masa. Este principio establece que las variaciones en la concentración para un contaminante dentro de un volumen de control resultan del balance entre el transporte, la dispersión, las emisiones y el procesos de remoción (Jacob, 2009; Fiore, 2015). En el contexto de la modelación atmosférica urbana, esta formulación es la base de los modelos físico–químicos que son utilizados para describir la dinámica de contaminantes en la troposfera (IPCC, 2022).

Luego, la ecuación de balance de masa advección–difusión (A–D) esta dada por la siguiente relación:

Sea $C(\mathbf{s}, t)$ la concentración del contaminante en la posición $\mathbf{s}$ y el tiempo t . La dinámica general puede representarse mediante una ecuación de advección–difusión con términos fuente y sumidero:

$$\frac{\partial C(\mathbf{s}, t)}{\partial t} = -\nabla \cdot (\mathbf{u}(\mathbf{s}, t) C(\mathbf{s}, t)) + \nabla \cdot (K(\mathbf{s}, t) \nabla C(\mathbf{s}, t)) + S(\mathbf{s}, t) - R(\mathbf{s}, t), \quad (3.7)$$

donde $\mathbf{u}(\mathbf{s}, t)$ es el campo de velocidad del viento (advección), $K(\mathbf{s}, t)$ es el coeficiente de difusión efectiva asociado a la mezcla turbulenta, $S(\mathbf{s}, t)$ son las fuentes de emisión y

$R(s, t)$ son los mecanismos de remoción (Jacob, 2009).

Donde el término de advección se refiere al transporte del contaminante por el movimiento del aire. Esto explica cómo las diferentes emisiones generadas en una región pueden afectar zonas adyacentes, dando una dependencia espacial entre áreas urbanas (Fiore, 2015).

El término de difusión representa la dispersión turbulenta, es la responsable de suavizar gradientes espaciales de concentración (IPCC, 2022).

Por otro lado, el término $S(s, t)$ agrupa las fuentes de emisión, que pueden asociarse principalmente al tráfico vehicular, actividad industrial y otras fuentes antropogénicas (Jacob, 2009). Por su parte, el término $R(s, t)$ representa los sumideros, incluyendo la deposición seca, la deposición húmeda asociada a precipitación y los procesos químicos de transformación atmosférica (Fiore, 2015).

Finalmente, aunque la formulación anterior tiene un dominio continuo, los datos observacionales disponibles corresponden a mediciones puntuales en estaciones de monitoreo. En consecuencia, el análisis empírico necesita de aproximaciones discretas del dominio espacial y temporal, por ejemplo, mediante una partición en celdas o cuadrículas (Banerjee, 2014).

Capítulo 4

Metodología

4.1 Enfoque metodológico general

Este estudio adopta un enfoque cuantitativo orientado a estimar la dinámica espacio-temporal de la contaminación del aire en Bogotá y a evaluar cómo dicha variabilidad se traduce en resultados sanitarios y económicos bajo distintos supuestos de análisis. La metodología se estructuró en tres etapas. La primera consistió en construir una representación operativa del comportamiento espacial y temporal de los contaminantes mediante un esquema discreto de advección-difusión sobre una malla regular de $3 \text{ km} \times 3 \text{ km}$. La segunda correspondió a la formulación de un modelo jerárquico bayesiano espacio-temporal, utilizado para estimar superficies continuas de concentración e incorporar explícitamente la incertidumbre asociada a la limitada cobertura espacial de las estaciones de monitoreo. La tercera etapa consistió en integrar dichas superficies en un esquema computacional de evaluación sanitaria y económica estructurado con base en la lógica metodológica de BenMAP-CE.

4.2 Fuentes de información y datos utilizados

La metodología se apoyó en cuatro bloques principales de información: datos de calidad del aire, variables meteorológicas, soporte espacial del dominio de análisis y datos demográficos y de salud. Estos bloques no cumplen la misma función dentro del estudio. Los datos de calidad del aire y meteorología se utilizaron en la construcción del esquema discreto de advección-difusión y en la formulación del modelo jerárquico bayesiano espacio-temporal,

mientras que la información demográfica y sanitaria se utiliza posteriormente en la etapa de evaluación sanitaria y económica. Por su parte, el soporte espacial permitió definir la malla regular sobre la cual se organizaron la interpolación, la estructura de vecindad y las superficies finales de concentración.

En particular, las concentraciones de $PM_{2.5}$, NO_2 y O_3 se obtuvieron a partir de la Red de Monitoreo de Calidad del Aire de Bogotá, y fueron posteriormente agregadas a escala mensual para su integración con la información meteorológica y con la modelación espacio-temporal. Las variables meteorológicas, especialmente la velocidad del viento, la temperatura, la humedad relativa y la precipitación, se utilizaron como un apoyo para caracterizar condiciones de transporte y dispersión atmosférica. Para el soporte espacial, se definió mediante una malla regular de $3\text{ km} \times 3\text{ km}$ construida sobre el área urbana de Bogotá en el sistema MAGNA-SIRGAS / Colombia Bogotá (EPSG:3116), la cual constituyó la base del esquema A-D y del HBM. Finalmente, los datos demográficos y de salud se incorporaron en la etapa de evaluación sanitaria y económica, con el fin de traducir los cambios en exposición en resultados de impacto comparables.

Cuadro 4.1. *Resumen de las fuentes de información utilizadas en el estudio*

Bloque de datos	Variables principales	Fuente	Frecuencia base	Uso en el estudio
Calidad del aire	PM _{2.5} , NO ₂ , O ₃	RM CAB	Horaria	Agregación mensual por estación, interpolación espacial y ajuste del HBM
Meteorología	Temperatura, humedad relativa, precipitación, velocidad del viento	IDEAM / NASA POWER	Diaria	Agregación mensual, interpolación a malla y construcción de covariables para A–D y HBM
Soporte espacial	Malla regular de 3 km × 3 km, cartografía base de Bogotá y localidades	Elaboración propia a partir de cartografía base de Bogotá	Fija	Definición del dominio espacial, estructura de vecindad e integración de resultados
Demográfica	Población total y estructura por edad y sexo	DANE	Anual	Evaluación sanitaria y económica
Sanitaria	Mortalidad total y por causas, morbilidad respiratoria	SISPRO / Secretaría Distrital de Salud	Anual	Evaluación sanitaria y económica

Elaboración propia con base en información de RM CAB, IDEAM, NASA POWER, DANE, SISPRO, Secretaría Distrital de Salud y cartografía base de Bogotá (2024).

4.3 Implementación del modelo de balance de masa tipo advección–difusión (A–D)

El componente de advección–difusión (A–D) se implementó como un esquema físico-operacional para caracterizar la variación espacio–temporal de las concentraciones de contaminantes PM_{2.5}, NO₂ y O₃ en Bogotá. Su propósito no fue resolver de manera completa la ecuación diferencial de transporte atmosférico, ni reproducir de forma determinística todos los procesos físicos, químicos y turbulentos que intervienen en la dinámica de los contaminantes. En cambio, se utilizó como una aproximación discreta orientada a construir variables derivadas con interpretación física ya que son útiles para describir contraste espacial, heterogeneidad local y potencial de transporte sobre una malla regular.

Esta observación es importante porque el estudio no dispone de inventarios horarios de emisiones, perfiles verticales de mezcla, dirección detallada del viento en cada celda, coeficientes de difusión turbulenta calibrados localmente ni tasas explícitas de reacción o de-

posición para cada contaminante. Por esta razón, la formulación A–D debe entenderse como un puente entre el marco físico del balance de masa y la modelación estadística posterior, y no como un modelo atmosférico determinístico completo. En consecuencia, los términos de difusión, gradiente y advección construidos en esta etapa se interpretan como covariables operativas que resumen propiedades locales del campo de concentración y no como estimaciones exactas de flujos atmosféricos.

4.3.1 Dominio, discretización, condiciones operativas y paso temporal del esquema A–D

El dominio espacial del análisis correspondió al área de Bogotá representada mediante una malla regular de $3 \text{ km} \times 3 \text{ km}$, construida en un sistema de referencia proyectado en metros, MAGNA–SIRGAS / Colombia Bogotá (EPSG:3116). Esta decisión permitió que las distancias entre estaciones, centroides y celdas fueran calculadas en unidades métricas y que el tamaño de celda tuviera una interpretación espacial mas directa. La malla fue recortada al contorno del distrito, de modo que cada celda representara una unidad espacial de análisis compatible con la interpolación de concentraciones, la construcción de vecindades y la generación de superficies posteriores del modelo jerárquico bayesiano.

La elección de una resolución de $3 \text{ km} \times 3 \text{ km}$ respondió a un balance entre el detalle espacial y soporte empírico. Una malla más fina habría aumentado artificialmente el número de unidades espaciales sin contar necesariamente con mayor información observacional de estaciones, mientras que una malla más gruesa habría reducido la capacidad de representar contrastes intraurbanos relevantes. Por tanto, esta resolución se consideró adecuada para integrar mediciones puntuales, variables meteorológicas interpoladas y resultados posteriores de exposición, salud y valoración económica.

Por otra parte, el dominio temporal se definió a escala mensual para el periodo 2020–2024. Aunque las mediciones originales de contaminantes provienen de registros horarios, estas fueron agregadas mensualmente con el fin de construir campos comparables entre contaminantes, reducir la influencia de fluctuaciones de muy corto plazo y mantener coherencia con los insumos utilizados en las etapas posteriores del estudio. Teniendo en cuenta lo ante-

rior, el paso temporal mensual no representa una integración dinámica de la ecuación física hora a hora, sino una actualización periódica de los campos espaciales de concentración y de las covariables derivadas. Esta decisión está alineada con el propósito de la investigación, que se centra en evaluar sensibilidad de cargas sanitarias y económicas bajo escenarios de exposición, y no en simular episodios atmosféricos de corta duración. Adicionalmente, el paso temporal mensual utilizado en este estudio no corresponde a un paso de integración explícita de la ecuación diferencial de advección-difusión. En consecuencia, no se aplicaron criterios de estabilidad numérica propios de esquemas dinámicos de solución de ecuaciones diferenciales, como el criterio de Courant-Friedrichs-Lewy (CFL). La escala mensual se adoptó como intervalo de agregación y actualización de los campos observados-interpolados y de las covariables derivadas, teniendo en cuenta la disponibilidad de los insumos, la estructura temporal de los datos observados y el objetivo de evaluar la sensibilidad de la exposición, la carga sanitaria y la valoración económica a escala mensual.

Las condiciones iniciales se definieron de manera operativa a partir del primer campo mensual interpolado disponible para cada contaminante. Dado que el esquema no resuelve una trayectoria dinámica acumulativa en el tiempo, dicha condición inicial no se interpreta como el punto de arranque de una simulación física completa, sino como el primer estado espacial observado-interpolado dentro del periodo de análisis. Cada mes fue tratado como una representación agregada del estado medio del contaminante sobre la malla, permitiendo comparar la evolución relativa de los campos sin imponer una dinámica física no observada.

Las condiciones de frontera se interpretaron como una frontera empírica del dominio de análisis. En las celdas ubicadas en el borde del contorno de Bogotá, los operadores espaciales se calcularon únicamente con las celdas vecinas disponibles dentro del dominio. Esta regla operativa permitió evitar la introducción de concentraciones externas no observadas o supuestos de flujo provenientes de fuera del área de estudio. Por tanto, la frontera no se definió como una condición física impuesta sobre una ecuación diferencial dinámica, sino como una restricción espacial coherente con la información disponible y con el carácter físico-operacional del esquema A-D.

Para la discretización espacial se realizó en dos momentos. Primero, las observaciones

puntuales de las estaciones fueron trasladadas a la malla mediante interpolación por distancia inversa, obteniendo campos mensuales de concentración para cada contaminante. Segundo, sobre esos campos interpolados se aplicó una estructura de vecindad tipo *Queen*, en la cual dos celdas se consideran vecinas si comparten borde o vértice. Esta estructura permitió aproximar operadores espaciales de forma discreta, calculando los contrastes entre cada celda y su entorno inmediato.

Bajo esta formulación, el término difusivo se interpretó como una medida de contraste local entre una celda y sus vecinas; el gradiente espacial como una medida de la intensidad promedio del cambio de concentración por distancia; y el proxy advectivo como una aproximación del potencial de transporte, obtenida al combinar la velocidad del viento interpolada con la magnitud del gradiente local. Por tanto, estos indicadores resumen propiedades físicas plausibles del campo de concentración, pero no sustituyen una estimación completa de la advección vectorial ni de la difusión turbulenta real.

La calibración del esquema A–D no consistió en estimar parámetros físicos como coeficientes de difusión, tasas de deposición o términos explícitos de reacción química, debido a que dichos insumos no estaban disponibles con la resolución espacial y temporal requerida para Bogotá. En su lugar, la calibración se entendió como una evaluación de consistencia y representatividad de los campos generados. Para ello se revisó la coherencia espacial de los campos interpolados, la estructura de autocorrelación espacial, la conectividad de la malla y la capacidad de la interpolación para reproducir los valores observados mediante validación cruzada.

En consecuencia, la validez del componente A–D depende de su capacidad para generar covariables físicamente interpretables, trazables y consistentes con los patrones observados, más que de reproducir de manera exacta la física completa del transporte atmosférico de los contaminantes. Esta distinción delimita el alcance del modelo y permite interpretar sus productos como insumos auxiliares para el modelo jerárquico bayesiano y para el análisis de sensibilidad.

Finalmente, debe señalarse que cualquier incertidumbre presente en los campos interpolados o en las covariables A–D puede propagarse hacia las etapas posteriores del estudio.

Si una zona de la malla tiene baja cobertura de estaciones o si el campo interpolado suaviza episodios extremos, las estimaciones de exposición, carga sanitaria y valoración económica asociadas a esa zona deben interpretarse con mayor cautela. Por ello, el esquema A–D se utilizó como una herramienta de caracterización y soporte para la modelación estadística, no como una fuente definitiva e independiente de exposición.

4.3.2 Interpolación mensual de concentraciones a la malla

Dado que las mediciones originales se encuentran en estaciones fijas y no sobre una superficie continua, fue necesario transformar esta información a un soporte espacial regular. Para ello, se utilizó interpolación por distancia inversa (*Inverse Distance Weighting*, IDW), aplicada de manera independiente para cada periodo y para cada contaminante. Este procedimiento permitió construir, sobre la malla de 3 km, un campo de concentraciones interpoladas que sirvió como base para el cálculo posterior de los términos discretos del esquema A–D.

Sea $\hat{C}_{i,t}$ la concentración interpolada del contaminante en la celda i durante el tiempo t . Su estimación se definió como:

$$\hat{C}_{i,t} = \frac{\sum_{s \in S_t} w_{is,t} C_{s,t}}{\sum_{s \in S_t} w_{is,t}}, \quad w_{is,t} = \frac{1}{d_{is}^p}, \quad (4.1)$$

donde S_t es el conjunto de estaciones con observación válida en el tiempo t , $C_{s,t}$ es la concentración observada en la estación s , d_{is} es la distancia entre la estación y el centroide de la celda i , y p es el parámetro de potencia del esquema IDW. En la implementación se utilizó $p = 2$ y, para mejorar la robustez del cálculo, la interpolación se restringió a las $k = 8$ estaciones válidas más cercanas cuando la disponibilidad de datos lo permitía.

La ecuación (4.1) se utilizó porque permite trasladar la información observada en puntos discretos a una superficie continua sobre la malla, asignando mayor influencia a las estaciones más próximas y menor influencia a las más alejadas. En este estudio, su función no fue producir la estimación final de concentraciones, sino construir un campo espacial intermedio coherente con la información observada y adecuado para derivar variables con interpretación física.

Este procedimiento se replicó para PM_{2.5}, NO₂ y O₃, generando un campo interpolado

sobre la totalidad de la malla y se almacenó en `grid_3km_idw_mensual_2020_2024.csv`, que contiene las concentraciones interpoladas por celda y mes y constituye la base espacial a partir de la cual se calcularon los términos discretos del esquema A–D.

Interpolación de la velocidad del viento. Con el objetivo de incorporar una variable meteorológica asociada al transporte atmosférico, la velocidad del viento también fue interpolada a la misma malla espacial y con la misma resolución temporal. Este paso fue necesario porque el componente advectivo del balance depende de la intensidad del movimiento del aire y, por tanto, requería una variable disponible en el mismo soporte celda–tiempo que las concentraciones interpoladas.

Sea $\hat{u}_{i,t}$ la velocidad del viento interpolada en la celda i y el tiempo t . Su estimación se realizó mediante el mismo esquema IDW definido en la ecuación (4.1), garantizando consistencia espacial entre el campo de contaminación y la covariable meteorológica. El resultado se incorporó posteriormente al archivo integrado de la malla bajo la variable `Vel_viento_idw`.

4.3.3 Construcción de la estructura de vecindad espacial

Para aproximar los operadores espaciales en forma discreta fue necesario definir para cada celda i un conjunto de vecinas $N(i)$. Esta estructura se construyó sobre la malla regular mediante un criterio de contigüidad tipo *Queen* en el cual dos celdas se consideran vecinas si comparten borde o vértice. La elección del criterio respondió a que ofrece una conectividad más flexible que la contigüidad tipo *Rook*, lo cual resulta conveniente en una grilla que está recortada al contorno urbano de Bogotá, donde algunas celdas periféricas podrían quedar excesivamente aisladas bajo una regla más restrictiva.

La vecindad se almacenó en una estructura de adyacencia equivalente a una matriz espacial W , exportada como `W_grid_3km_queen.csv`. Este archivo constituye el insumo fundamental para el cálculo de los términos difusivos y de gradiente espacial, ya que define qué celdas participan en la comparación local de concentraciones.

Cálculo discreto del término difusivo. Una vez construido el campo interpolado $\hat{C}_{i,t}$ y definida la estructura de vecindad, se calculó una aproximación discreta del componente

difusivo. Conceptualmente, la difusión representa el mecanismo mediante el cual los contrastes de concentración tienden a suavizarse en el espacio. Este comportamiento se aproximó mediante el contraste neto entre la celda de interés y sus vecinas inmediatas:

$$\text{Diff}(C)_{i,t} = \sum_{j \in N(i)} (\hat{C}_{j,t} - \hat{C}_{i,t}). \quad (4.2)$$

La ecuación (4.2) se utilizó como una medida discreta del entorno local de concentración. Cuando el valor es positivo indica que la vecindad presenta concentraciones mayores que la celda analizada; cuando es negativo indica que la celda presenta niveles superiores a los de su entorno. Aunque no corresponde al Laplaciano continuo en sentido estricto, sí constituye una aproximación coherente con la lógica difusiva del balance de masa y resume de manera útil el contraste espacial local. En la implementación final, este cálculo se realizó por separado para PM_{2.5}, NO₂ y O₃, generando las variables `diff_PM25_grid`, `diff_NO2_grid` y `diff_O3_grid`.

Gradiente espacial local. Adicionalmente del contraste neto con la vecindad, se construyó una medida que resumiera la intensidad del cambio espacial local en función de la distancia entre centroides. Para ello, se definió un gradiente espacial discreto basado en diferencias absolutas entre la celda de interés y sus vecinas, escaladas por la distancia entre centroides:

$$\text{Grad}(C)_{i,t} = \frac{1}{|N(i)|} \sum_{j \in N(i)} \frac{|\hat{C}_{j,t} - \hat{C}_{i,t}|}{d_{ij}}, \quad (4.3)$$

donde $N(i)$ representa el conjunto de celdas vecinas de la celda i , $|N(i)|$ corresponde al número de vecinas disponibles, $\hat{C}_{i,t}$ es la concentración interpolada en la celda i durante el periodo t , $\hat{C}_{j,t}$ es la concentración interpolada en la celda vecina j y d_{ij} es la distancia entre los centroides de las celdas i y j . La ecuación 4.3 no busca representar una dirección vectorial del cambio, sino la magnitud promedio de la variación espacial por unidad de distancia.

Por tanto, valores altos de $\text{Grad}(C)_{i,t}$ indican que la celda i presenta diferencias marcadas de concentración frente a su entorno inmediato, mientras que valores bajos sugieren una superficie local más homogénea. Esta medida permitió identificar zonas y periodos con mayor

contraste espacial, lo cual resulta útil para caracterizar discontinuidades locales en los campos de concentración y para complementar la información proveniente del término difusivo.

En la implementación computacional, este indicador se calculó de manera independiente para $PM_{2.5}$, NO_2 y O_3 , generando las variables `grad_PM25_grid`, `grad_NO2_grid` y `grad_O3_grid`. Estas variables fueron utilizadas como covariables espaciales derivadas del esquema de advección–difusión dentro del panel de modelación posterior.

Construcción del proxy advectivo. El componente advectivo del balance de masa se asocia al transporte del contaminante por el movimiento del aire. En un modelo físico completo, este término depende tanto de la velocidad como de la dirección del viento y de la geometría del gradiente espacial. No obstante, dado que el objetivo de esta etapa fue construir una aproximación parsimoniosa y consistente con la información disponible, se definió un proxy advectivo de magnitud que combina la velocidad del viento interpolada con la intensidad del gradiente espacial local:

$$Adv(C)_{i,t} = \hat{u}_{i,t} Grad(C)_{i,t}. \quad (4.4)$$

La ecuación (4.4) se utilizó para representar el potencial local de transporte atmosférico. A igualdad de gradiente, un mayor viento incrementa el valor del indicador; a igualdad de viento, un gradiente espacial más fuerte también lo eleva. En consecuencia, este término resume de manera operativa la idea de que el transporte resulta más relevante cuando coinciden contraste espacial y movimiento del aire, sin embargo, esta construcción no incorpora la dirección del viento, por lo cual no debe interpretarse como una estimación vectorial exacta de la advección. Su utilidad radica en funcionar como un descriptor físico simplificado que posteriormente puede incorporarse como covariable explicativa en el HBM.

En la implementación final, este cálculo generó las variables `adv_proxy_PM25_grid`, `adv_proxy_NO2_grid` y `adv_proxy_O3_grid`.

4.3.4 Tratamiento de valores faltantes y casos límite

Durante el procesamiento se presentaron valores faltantes en algunos registros intermedios. Este comportamiento se consideró esperable en dos situaciones. La primera ocurrió

cuando, en un tiempo determinado, un contaminante no contaba con suficientes observaciones válidas para sostener una interpolación confiable. La segunda apareció cuando una celda no disponía de información vecina suficiente para calcular de manera consistente los términos espaciales derivados del esquema A–D.

En estos casos, el procedimiento conservó los valores faltantes en lugar de forzar imputaciones adicionales. Esta decisión se adoptó para evitar la incorporación de información artificial en una etapa cuyo objetivo era derivar covariables con interpretación física directamente a partir de datos observados e interpolados. En consecuencia, se priorizó la trazabilidad del proceso y la coherencia entre calidad de datos y variables construidas.

Antes de utilizar los productos interpolados como base del esquema A–D, se realizó una validación preliminar del campo espacial generado por IDW. Para ello, cada observación se asoció a la celda de la malla más cercana según distancia entre coordenadas proyectadas, y luego se comparó el valor observado con el valor interpolado en esa celda y en el mismo tiempo. La evaluación se resumió mediante métricas globales de desempeño, incluyendo error absoluto medio (MAE), raíz del error cuadrático medio (RMSE), sesgo medio y correlación lineal. Este paso permitió verificar que el campo interpolado capturara razonablemente la variabilidad observada antes de ser utilizado para derivar variables de difusión y advección.

La validación realizada en esta etapa no tuvo como propósito demostrar que el campo interpolado reprodujera exactamente las mediciones puntuales, sino comprobar que ofreciera una representación espacial suficientemente consistente para servir como base de la modelación posterior.

4.3.5 Productos generados en la etapa A–D

La implementación del esquema A–D proporciona tres insumos para las etapas posteriores del estudio. En primer lugar, se generó el archivo `grid_3km_idw_mensual_2020_2024.csv`, que contiene las concentraciones mensuales interpoladas de $PM_{2.5}$, NO_2 y O_3 sobre la malla regular determinada anteriormente. En segundo lugar, el archivo `W_grid_3km_queen.csv`, correspondiente a la estructura de vecindad espacial tipo *Queen* definida sobre las celdas de la malla y en tercer lugar, el archivo `grid_3km_AD_mensual_2020_2024.csv`, que integra el

campo interpolado, la velocidad del viento interpolada y las variables derivadas del esquema A–D.

Este último archivo constituyó el producto central de la etapa metodológica, ya que reúne, para cada celda y cada mes, las concentraciones interpoladas (PM25_idw, NO2_idw, O3_idw), la velocidad del viento interpolada (Vel_viento_idw), los términos difusivos (diff_grid), las medidas de gradiente espacial (grad_grid) y los proxies advectivos (adv_proxy_grid).

En términos metodológicos, estos productos permitieron transformar una formulación física general en un conjunto concreto de variables espacio–temporales observables, trazables y compatibles con la etapa posterior de modelación jerárquica bayesiana. Por esta razón, la etapa A–D funcionó como un puente entre el marco físico del balance de masa y la construcción del HBM.

4.4 Modelo jerárquico bayesiano espacio–temporal

Con el fin de estimar superficies espacio–temporales continuas de concentración para PM_{2.5}, NO₂ y O₃ en Bogotá, se implementa un modelo jerárquico bayesiano sobre una malla regular de 3 km × 3 km. Este modelo se formuló como un componente complementario al esquema de advección–difusión desarrollado en la sección anterior. Mientras la etapa A–D permitió construir covariables con interpretación física asociadas al transporte y la dispersión local, el modelo jerárquico bayesiano se utilizó para integrar la información observada en estaciones, representar la dependencia espacial y temporal residual, y cuantificar explícitamente la incertidumbre de las estimaciones sobre toda la malla de análisis (Banerjee et al., 2014; Carvour et al., 2018).

El propósito para este componente no fue reproducir únicamente los valores observados en estaciones sino reconstruir un proceso latente continuo de concentración para cada contaminante sobre el dominio espacial de estudio y a partir de este proceso latente se obtuvieron superficies mensuales resumidas mediante percentiles posteriores, en particular *P05*, *P50* y *P95*, así como el ancho del intervalo central del 90 %. Estas salidas constituyeron el insumo final del componente HBM y la base para la construcción de escenarios de exposi-

ción en el análisis de sensibilidad y en la etapa posterior de evaluación sanitaria y económica estructurada con base en la lógica metodológica de BenMAP-CE (Sacks et al., 2018; EPA, 2024).

4.4.1 Caracterización de los observables y justificación estadística del HBM

La construcción del modelo jerárquico bayesiano partió de una revisión previa de los observables que están disponibles para cada contaminante. En este estudio, los observables correspondieron a las concentraciones mensuales registradas en estaciones de monitoreo para $PM_{2.5}$, NO_2 y O_3 , asociadas posteriormente a la celda de la malla más cercana mediante el identificador `cell_id`. Esta decisión permitió mantener como variable respuesta las mediciones reales de la estación y no las concentraciones interpoladas por IDW. En consecuencia, el HBM se ajustó a partir de información observada, mientras que las superficies interpoladas y las variables derivadas del esquema A–D se utilizaron como `covariables auxiliares` y no como sustitutos directos de la respuesta.

Desde el punto de vista estadístico, los contaminantes presentaron atributos diferentes en términos de cobertura, variabilidad y comportamiento temporal. Por un lado, $PM_{2.5}$ mostró mayor estabilidad en disponibilidad de datos pero también mayor dispersión y presencia de valores extremos. Por otro lado, NO_2 presentó una señal espacio–temporal más consistente y con mejor correspondencia entre observaciones y predicciones en las etapas de validación. Finalmente, O_3 mostró un comportamiento más dependiente de oscilaciones temporales y estacionales, razón por la cual fue necesario incorporar un efecto mensual explícito en su especificación final. Esta diferenciación justificó que los modelos se ajustaran por contaminante de manera independiente para así evitar imponer una misma estructura empírica a procesos atmosféricos con dinámicas distintas.

La transformación logarítmica aplicada a la respuesta tuvo como propósito estabilizar la escala de las concentraciones, reducir la influencia de valores extremos y garantizar predicciones positivas al retornar a la escala original. Esta decisión fue especialmente importante porque las concentraciones atmosféricas son variables continuas no negativas y pueden presentar asimetrías, dispersión heterogénea y diferencias de magnitud entre contaminantes. Bajo

este enfoque, el modelo no buscó únicamente reproducir valores puntuales, sino estimar un proceso latente de concentración que combinara la información observada, las covariables físicas disponibles y la estructura espacio–temporal residual.

Las covariables incluidas provinieron del esquema de advección–difusión y de la interpolación meteorológica. En particular, se consideraron variables como la velocidad del viento interpolada, el término difusivo, el gradiente espacial y el proxy advectivo. Antes de definir la especificación final, estas variables fueron revisadas en términos de valores faltantes, colas extremas, redundancia y estabilidad numérica. Como resultado, para $PM_{2.5}$ y NO_2 se conservó una versión depurada de las covariables, compuesta por velocidad del viento interpolada, término difusivo transformado y proxy advectivo limpio. En el caso de O_3 , además de estas covariables, se añadió un efecto estacional mensual debido a la mayor importancia de la variabilidad intra-anual en este contaminante.

Esta caracterización de los observables permitió justificar el uso de un HBM por tres razones principales. Primero, la red de estaciones no cubre homogéneamente todo el dominio espacial, por lo cual se requiere un modelo capaz de transferir información entre celdas cercanas. Segundo, las concentraciones presentan dependencia temporal, lo que hace inadecuado tratarlas como observaciones independientes entre meses. Tercero, la evaluación sanitaria y económica posterior necesita no solo una superficie central de exposición, sino también una representación explícita de la incertidumbre. Por estas razones, el enfoque jerárquico bayesiano resultó adecuado para articular observaciones, covariables, efectos espaciales, efectos temporales e incertidumbre posterior dentro de una misma estructura probabilística.

4.4.2 Unidad de análisis y dominio espacio–temporal

La unidad de análisis del modelo correspondió a la combinación entre celda espacial y tiempo. El dominio del estudio se discretizó mediante una malla regular de $3\text{ km} \times 3\text{ km}$ sobre el área urbana de Bogotá, obteniéndose un total de 254 celdas espaciales. Sobre esta malla se definió un panel mensual entre enero de 2020 y diciembre de 2024, equivalente a 60 unidades temporales. Esta estructura permitió representar el proceso latente de las concentración sobre combinaciones celda–tiempo, manteniendo consistencia con la resolución empleada en

la interpolación, el esquema A–D y la validación temporal del modelo.

Las observaciones provenientes de las estaciones de monitoreo se asociaron a la celda más cercana de la malla mediante el identificador `cell_id`. De esta forma, cada observación mensual válida se vincula con el proceso latente definido sobre el dominio espacial completo y con las covariables construidas para la celda y el mes correspondientes. Esta estrategia permitió utilizar la información realmente observada para ajustar el modelo y, posteriormente, generar predicciones para todas las celdas de la malla.

4.4.3 Construcción de los paneles de modelación

Para cada contaminante se construyeron dos insumos principales para el ajuste del modelo. El primero correspondió a un panel observado, conformado por las concentraciones válidas registradas en estaciones, junto con la fecha, la estación, la celda asociada y las covariables espaciales y temporales correspondientes. El segundo correspondió a un panel de malla, definido para todas las combinaciones celda–tiempo del dominio de estudio, sobre el cual se integraron las covariables meteorológicas interpoladas y los términos derivados del esquema de advección–difusión.

El panel observado se utilizó para el ajuste y la validación fuera de muestra del modelo, mientras que el panel de malla se empleó para generar predicciones sobre la totalidad del dominio espacial ya que esta separación fue metodológicamente importante porque distinguió entre la información efectivamente observada y la superficie completa sobre la cual se buscó estimar el proceso latente. Para facilitar la implementación computacional, ambos paneles se organizaron mediante índices espaciales y temporales consecutivos, denotados por `cell_idx` y `time_idx`, los cuales permitieron vincular observaciones, covariables y efectos aleatorios dentro de una misma estructura jerárquica.

4.4.4 Variables de entrada al modelo

La variable respuesta del modelo correspondió a la concentración observada de cada contaminante en las estaciones de monitoreo con registros válidos. Los tres contaminantes se modelaron de forma independiente ya que tienen tanto procesos atmosféricos como patrones

de variación diferentes. Adicionalmente, como predictores del proceso latente se utilizaron covariables definidas sobre la malla y construidas en las etapas previas de la metodología en las cuales son, la velocidad del viento interpolada y términos derivados del esquema A–D asociados al contraste difusivo y al potencial advectivo local.

Antes del ajuste definitivo, las covariables del panel de malla fueron auditadas en términos de rangos, colas extremas, valores faltantes y colinealidad. Como resultado de esta etapa, la especificación final para $PM_{2.5}$ y NO_2 conservó tres covariables principales: `Vel_viento_idw_clean`, `diff__grid_slog_clean` y `adv_proxy__grid_clean`. El gradiente espacial se inspeccionó y transformó, pero no se mantuvo en la especificación final cuando mostró redundancia alta con el proxy advectivo. En el caso de O_3 , además de estas covariables limpias, se incorporó un efecto estacional mensual explícito, debido a que la especificación sin estacionalidad tendía a suavizar en exceso las oscilaciones temporales del contaminante.

Nivel de observación. Sea $Y_{s,t}$ la concentración observada del contaminante en la estación s durante el tiempo t . Estas observaciones se vincularon con la celda $i(s)$ de la malla a la cual fue asociada cada estación. Con el fin de estabilizar la escala de la respuesta y garantizar predicciones positivas al regresar a la escala original, se trabajó sobre una transformación logarítmica de la concentración observada. El nivel de observación se expresó como:

$$\log(Y_{s,t} + \varepsilon) \sim \mathcal{N}(\mu_{i(s),t}, \sigma_y^2), \quad (4.5)$$

donde $\mu_{i(s),t}$ representa la media del proceso latente en la celda asociada a la estación s y tiempo t , σ_y^2 corresponde a la varianza del error observacional y ε es una constante pequeña introducida para evitar diferentes problemas numéricos cuando la concentración toma valores cercanos a cero. Esta ecuación se utilizó para conectar la observación puntual en estación con la superficie latente definida sobre la malla, manteniendo una formulación probabilística adecuada para la inferencia bayesiana.

Nivel del proceso latente. Para $PM_{2.5}$ y NO_2 , el proceso latente se definió como una combinación de covariables observadas sobre la malla, un efecto espacial estructurado y un efecto temporal común. La forma general fue

$$\mu_{i,t} = \alpha + \mathbf{x}_{i,t}^\top \boldsymbol{\beta} + \phi_i + \delta_t, \quad (4.6)$$

donde α es un intercepto global, $\mathbf{x}_{i,t}$ es el vector de covariables disponibles para la celda i y el tiempo t , $\boldsymbol{\beta}$ es el vector de coeficientes de regresión, ϕ_i representa el efecto espacial estructurado y δ_t el efecto temporal compartido por todas las celdas en el tiempo t . Esta ecuación permitió descomponer la variación de la concentración en una parte explicada por covariables observadas y una parte residual capturada mediante efectos estructurados en espacio y tiempo.

En el caso de O_3 , la estructura anterior se amplió con un término estacional mensual explícito, con el fin de representar de manera más adecuada la oscilación intra-anual del contaminante. La especificación final se expresó como

$$\mu_{i,t} = \alpha + \mathbf{x}_{i,t}^\top \boldsymbol{\beta} + \phi_i + \delta_t + m_{m(t)}, \quad (4.7)$$

donde $m_{m(t)}$ representa el efecto correspondiente al tiempo asociado al instante t (mes del año). La inclusión de este término ayudó a mejorar la capacidad del modelo para seguir el patrón temporal de O_3 , especialmente frente a especificaciones que solo incluían continuidad temporal mediante RW(1).

4.4.5 Estructura espacial

La dependencia espacial residual entre celdas se incorporó mediante un efecto aleatorio estructurado ϕ_i , definido a partir de una vecindad tipo *Queen* sobre la malla regular. Esta estructura se utilizó porque permite representar la similitud esperada entre celdas contiguas, bajo el supuesto de que zonas espacialmente cercanas tienden a presentar comportamientos más parecidos en concentración una vez descontado el efecto de las covariables observadas (Banerjee et al., 2014).

Para ello se adoptó una especificación del tipo ICAR (*Intrinsic Conditional Autoregressive*), en la que el efecto espacial de cada celda depende de los efectos correspondientes a sus vecinas. En forma condicional, la estructura puede expresarse como

$$\phi_i \mid \phi_{-i}, \tau_\phi \sim \mathcal{N}\left(\frac{1}{n_i} \sum_{j \sim i} \phi_j, \frac{1}{n_i \tau_\phi}\right), \quad (4.8)$$

donde n_i es el número de vecinas de la celda i , $j \sim i$ indica que la celda j es vecina de i , y τ_ϕ es el parámetro de precisión espacial. Esta formulación se utilizó porque suaviza espacialmente las estimaciones y captura heterogeneidad residual no explicada por las covariables, preservando al mismo tiempo la estructura de contigüidad definida sobre la malla.

4.4.6 Estructura temporal

La dependencia temporal se representó mediante un efecto aleatorio δ_t común a todas las celdas en el tiempo, con el fin de modelar la evolución global de las concentraciones a lo largo del periodo de estudio. Para ello se adoptó una estructura de caminata aleatoria de primer orden, RW(1), dada por

$$\delta_t \mid \delta_{t-1}, \sigma_t^2 \sim \mathcal{N}(\delta_{t-1}, \sigma_t^2), \quad (4.9)$$

donde σ_t^2 controla la variabilidad entre meses consecutivos. Esto se utilizó porque permite capturar continuidad temporal sin imponer una forma funcional rígida, lo cual resulta adecuado para series mensuales de contaminación atmosférica.

En el caso de O_3 , la estructura RW(1) se complementó con un efecto estacional mensual $m_{m(t)}$, definido sobre los doce meses del año y centrado para asegurar identificabilidad. Su inclusión respondió a la necesidad de representar oscilaciones temporales recurrentes que no eran capturadas de manera suficiente por la continuidad temporal del RW(1) por sí sola.

Distribuciones previas y regularización. Se especificaron distribuciones previas débiles pero regularizantes para los parámetros del modelo con el fin de estabilizar la estimación y evitar soluciones extremas en presencia de colinealidad o variabilidad alta en algunas covariables. En términos generales, se asignaron distribuciones Normales al intercepto global y a los coeficientes de regresión, mientras que para los parámetros de escala y precisión se utilizaron distribuciones restringidas a valores positivos, tales como Half-Normal y Exponencial. Esta estrategia fue consistente con la necesidad de mantener una inferencia estable y de

reducir problemas de convergencia en las distintas especificaciones comparadas.

Estrategia de ajuste computacional. La estimación del modelo se realizó en el lenguaje Python mediante inferencia bayesiana por cadenas de Markov Monte Carlo (MCMC), utilizando el algoritmo No-U-Turn Sampler (NUTS). Para cada especificación se ejecutaron múltiples cadenas independientes, con periodos de calentamiento y muestreo posterior, con el fin de aproximar la distribución posterior conjunta de los parámetros y durante el proceso de ajuste se emplearon configuraciones progresivamente más estables del muestreador, aumentando el número de iteraciones de calentamiento y el parámetro `target_accept` cuando fue necesario mejorar la estabilidad numérica.

Validación temporal. La capacidad predictiva del modelo se evaluó mediante una estrategia de validación temporal fuera de muestra, con el fin de preservar la estructura cronológica de la información y evitar particiones aleatorias que indujeran fuga de información entre entrenamiento y prueba. Para ello se definieron tres particiones sucesivas: entrenamiento con 2020–2021 y evaluación sobre 2022; entrenamiento con 2020–2022 y evaluación sobre 2023; y entrenamiento con 2020–2023 y evaluación sobre 2024. Este esquema permitió evaluar la capacidad del modelo para generalizar a periodos posteriores no observados durante el ajuste, manteniendo una lógica coherente con la dinámica temporal de la contaminación atmosférica.

4.4.7 Métricas de evaluación predictiva

La comparación entre especificaciones del modelo se realizó a partir de métricas orientadas tanto al ajuste central como a la calibración de la incertidumbre. En primer lugar, se calcularon el error absoluto medio (MAE), el error absoluto mediano (MedAE), la raíz del error cuadrático medio (RMSE) y el sesgo medio (Bias), con el fin de evaluar la magnitud y dirección del error de predicción en los periodos de validación. Adicionalmente, se estimó la correlación lineal r entre valores observados y predichos, como una medida del seguimiento del patrón temporal y de la asociación entre ambas series.

Calibración del modelo bayesiano. La calibración del HBM se entendió como el proceso de ajustar la estructura probabilística del modelo a los datos observados, verificando

simultáneamente la estabilidad de los parámetros, la coherencia de los efectos latentes y la capacidad predictiva fuera de muestra. Siendo así, la calibración no consistió únicamente en minimizar una métrica de error puntual, sino en alcanzar un balance entre ajuste central, incertidumbre posterior, estabilidad computacional y plausibilidad espacial y temporal de las superficies estimadas.

Para evitar fuga de información temporal, las covariables fueron escaladas utilizando únicamente los años de entrenamiento en cada fold de validación. Posteriormente, esos parámetros de escalamiento se aplicaron al periodo de prueba. Esta decisión permitió evaluar el desempeño del modelo bajo una lógica más cercana a predicción fuera de muestra.

El proceso de calibración incluyó la comparación de especificaciones sucesivas. En una primera etapa se evaluaron modelos con estructura espacial ICAR y estructura temporal RW(1), incorporando covariables derivadas del esquema A–D. Posteriormente, se depuraron covariables con alta redundancia o comportamiento extremo, dando lugar a las versiones limpias del modelo para PM_{2.5} y NO₂. En el caso de O₃, la inspección de las series y de las predicciones mostró que la estructura ICAR + RW(1) tendía a suavizar en exceso la variación intra-anual, por lo que se incorporó un efecto estacional mensual.

La calibración final se apoyó en los diagnósticos de muestreo MCMC y en la revisión de las predicciones obtenidas para los años de prueba. Se consideraron indicadores como MAE, RMSE, cobertura del intervalo creíble del 90 % y ancho medio del intervalo. Adicionalmente, se revisaron diagnósticos bayesianos como $\hat{R}$, tamaños efectivos de muestra, divergencias y advertencias del muestreador. De esta forma, la selección del modelo final no dependió de una sola métrica, sino de una evaluación conjunta del desempeño predictivo, la calibración de la incertidumbre y la estabilidad inferencial.

Diagnósticos de convergencia. Además del desempeño predictivo, cada especificación del modelo fue evaluada mediante diagnósticos de convergencia y calidad del muestreo posterior. En particular, se revisó el estadístico $\hat{R}$, el tamaño efectivo de muestra en sus versiones *bulk* y *tail*, así como la presencia de divergencias durante el muestreo y advertencias asociadas a la profundidad máxima del árbol de exploración. Estos diagnósticos permitieron verificar que la mezcla entre cadenas, la estabilidad inferencial y la geometría posterior fueran

adecuadas antes de seleccionar un modelo final.

4.4.8 Selección del modelo final por contaminante

La selección del modelo final se realizó de manera independiente para cada contaminante, considerando conjuntamente el desempeño predictivo, la calibración de los intervalos de incertidumbre y los diagnósticos de convergencia. Para $PM_{2.5}$ y NO_2 la especificación seleccionada correspondió a la versión *M1b_clean*, la cual conservó la estructura espacial ICAR, la estructura temporal RW(1) y el conjunto depurado de covariables compuesto por velocidad del viento interpolada, término difusivo transformado y proxy advectivo depurado. Esta formulación ofreció el mejor compromiso entre estabilidad computacional, coherencia física de los predictores y capacidad predictiva.

En el caso de O_3 , la especificación final correspondió a una versión estacional, que conservó la estructura ICAR y el componente temporal RW(1), pero añadió un efecto estacional mensual explícito. Esta modificación se adoptó debido a que las versiones sin estacionalidad tendían a suavizar en exceso la dinámica temporal del contaminante. La inclusión del término estacional mejoró la representación del patrón mensual observado y permitió obtener un balance más adecuado entre error predictivo, sesgo, calibración de la incertidumbre y estabilidad inferencial.

4.4.9 Legitimación de los campos espacio-temporales generados

Los campos espacio-temporales generados por el HBM se legitimaron mediante una combinación de criterios estadísticos, espaciales, temporales y prácticos. En primer lugar, la legitimación estadística se basó en el uso de observaciones reales de estaciones como variable respuesta, lo que evitó ajustar el modelo directamente sobre superficies interpoladas.

En segundo lugar, la legitimación espacial provino de la incorporación de una estructura ICAR definida sobre la vecindad tipo *Queen*. Esta formulación permitió representar la dependencia esperada entre celdas contiguas y suavizar las estimaciones en zonas con menor soporte observacional, sin eliminar completamente las diferencias espaciales entre áreas. La validez espacial de los campos estimados se interpretó, por tanto, en función de su capacidad

para producir superficies continuas, coherentes con la estructura de vecindad y consistentes con los patrones generales identificados en los campos interpolados y en las estaciones.

En tercer lugar, la legitimación temporal se apoyó en la estructura RW(1), que permitió capturar continuidad entre meses consecutivos sin imponer una tendencia rígida. Esta característica resultó adecuada para datos agregados mensualmente, donde se espera cierta persistencia temporal, pero también cambios graduales asociados a condiciones meteorológicas, variabilidad de emisiones y dinámica propia de cada contaminante. En el caso de O_3 , la inclusión del efecto estacional mensual reforzó esta legitimación temporal, al reconocer que su comportamiento no depende únicamente de continuidad entre meses, sino también de patrones intra-anales recurrentes.

En cuarto lugar, la validez práctica de los campos se evaluó a partir de su utilidad para la etapa posterior de exposición, salud y valoración económica. Los productos del HBM no se interpretaron como mediciones exactas de concentración en cada celda, sino como superficies probabilísticas de exposición, resumidas mediante percentiles posteriores. El percentil 50 representó el escenario central, mientras que los percentiles 5 y 95 permitieron construir escenarios bajo y alto dentro del análisis de sensibilidad.

Por lo anterior, la validez del HBM no debe entenderse como una confirmación absoluta de que las superficies estimadas reproducen exactamente la concentración real en cada celda y mes. Más bien, debe interpretarse como una validez condicionada: los campos son defendibles en la medida en que se basan en observaciones reales, incorporan dependencias espacio-temporales justificadas, presentan desempeño predictivo razonable, muestran diagnósticos de convergencia aceptables y permiten representar incertidumbre mediante intervalos posteriores. En consecuencia, las estimaciones sanitarias y económicas derivadas de estos campos deben leerse como resultados condicionados por la calidad del modelo ambiental y no como valores determinísticos definitivos.

Productos finales del modelo jerárquico bayesiano. Como resultado del ajuste final, para cada contaminante se obtuvieron superficies espacio-temporales de concentración sobre la totalidad de la malla y para cada uno de los meses del periodo 2020–2024. Estas superficies se resumieron mediante cuatro salidas principales: el percentil 5 ($P05$), el percentil

50 (*P*50), el percentil 95 (*P*95) y el ancho del intervalo central del 90 %. El percentil 50 se adoptó como superficie central de concentración, mientras que los percentiles 5 y 95 se utilizaron para representar escenarios bajo y alto de exposición dentro del análisis de sensibilidad.

Estos productos constituyeron la salida final del componente HBM y la base para las etapas posteriores del estudio. En particular, sirvieron como insumo para la construcción de escenarios de exposición comparables y para la evaluación sanitaria y económica desarrollada bajo la lógica metodológica de BenMAP-CE, sin depender de que toda la implementación se ejecutara de manera cerrada dentro del software.

4.5 Módulo computacional de evaluación sanitaria y económica

Una vez que son obtenidas las superficies de concentración para PM_{2.5}, NO₂ y O₃, se implementó un módulo computacional para la evaluación sanitaria y económica inspirado en la lógica de BenMAP-CE, pero ejecutado en el lenguaje Python. Esta decisión permitió conservar la estructura conceptual de dicha herramienta y realizar comparaciones bajo escenarios de calidad del aire, aplicación de funciones CR, estimación de cambios en eventos de salud y valoración económica sin depender de la ejecución del software propio. Este enfoque es coherente con el propósito de BenMAP-CE, que no modela directamente la calidad del aire, sino que utiliza superficies externas de concentración para traducir cambios en exposición en impactos sanitarios y monetarios comparables entre escenarios (Sacks et al., 2018; U.S. EPA, 2023; EPA, 2024).

Desde el punto de vista metodológico, el módulo cumplió dos funciones dentro del estudio: 1. permitió convertir las superficies espacio temporales estimadas en la etapa previa en indicadores de carga sanitaria atribuible, expresados como cambios esperados en eventos de salud, 2. traducir dichos cambios en valores monetarios homogéneos, facilitando la comparación entre contaminantes, desenlaces y unidades territoriales y de este modo, el componente sanitario y económico operó como el puente entre la modelación de exposición y el análisis posterior de sensibilidad.

4.5.1 Construcción de escenarios de exposición

La evaluación sanitaria y económica se realizó a partir de escenarios de calidad del aire definidos sobre la misma malla regular de 3×3 km utilizada en las etapas previas. Se trabajó con superficies de concentración consistentes en resolución espacial, periodo de análisis y contaminante, de manera que la comparación entre escenarios reflejara únicamente cambios en exposición y no diferencias debidas a incompatibilidades en la estructura de los datos. De esta manera, se cumple con el requerimiento bajo la lógica BenMAP-CE, que la definición de la malla, la población, las tasas base y los datos de concentración son compatibles entre sí (U.S. EPA, 2023).

En la corrida base, el escenario central se construyó a partir de las superficies posteriores centrales estimadas por el modelo jerárquico bayesiano. A partir de estas superficies, se generaron los insumos necesarios para cuantificar impactos sanitarios y económicos en la malla y posteriormente agregarlos por localidad. Esta formulación permitió que la corrida base funcionara como referencia para los ejercicios comparativos desarrollados en el análisis de sensibilidad.

4.5.2 Estimación del cambio en eventos de salud

El cálculo sanitario siguió la estructura general de las funciones de impacto utilizadas en BenMAP-CE, es decir, el cambio esperado en un desenlace de salud depende de cuatro componentes: el cambio en la concentración del contaminante, el parámetro epidemiológico asociado a la función concentración–respuesta, el tamaño de la población expuesta y la tasa base del evento considerado (U.S. EPA, 2023; EPA, 2024). Para funciones de tipo log-lineal, esta relación puede expresarse como:

$$\Delta Y_{i,e} = Pop_{i,e} y_{0,i,e} \left(e^{\beta_e \Delta C_i} - 1 \right), \quad (4.10)$$

donde $\Delta Y_{i,e}$ representa el cambio esperado en el número de eventos del *endpoint* e en la celda i ; $Pop_{i,e}$ es la población expuesta; $y_{0,i,e}$ es la tasa base del evento; β_e es el coeficiente epidemiológico de la función concentración–respuesta; y ΔC_i corresponde al cambio en la

concentración del contaminante entre escenarios.

Esta formulación permite interpretar el módulo sanitario como una etapa de propagación del cambio en exposición hacia cambios esperados en morbilidad o mortalidad. Esta utilidad no radica únicamente en producir un número agregado de casos evitados, sino en mantener la trazabilidad entre el patrón espacial de concentración, la población afectada y la respuesta epidemiológica asociada a cada desenlace.(Sacks et al., 2018; Safari et al., 2022).

4.5.3 Funciones concentración–respuesta seleccionadas

Las funciones concentración–respuesta utilizadas en el módulo fueron seleccionadas con base en tres criterios: i) pertinencia respecto al contaminante analizado, ii) disponibilidad de evidencia epidemiológica utilizable en una formulación compatible con BenMAP-CE, y iii) coherencia con los desenlaces efectivamente incorporados en la corrida base. En este estudio, los *endpoints* finalmente retenidos correspondieron a mortalidad por todas las causas para PM_{2.5}, hospitalizaciones por asma y por enfermedad pulmonar crónica para NO₂, y mortalidad respiratoria para O₃.

La selección no buscó agotar todos los efectos posibles de la contaminación atmosférica, sino construir un conjunto acotado de funciones con suficiente respaldo conceptual y operativamente integrables al flujo del módulo. Este criterio de parsimonia resulta consistente con aplicaciones locales de BenMAP, donde la robustez del ejercicio depende más de la coherencia entre insumos y desenlaces que de la inclusión indiscriminada de funciones. En el caso de Bogotá, antecedentes como el de Ramírez et al. (2013) muestran precisamente la utilidad de adaptar este tipo de esquemas a información disponible localmente y de desagregar los resultados en el espacio para apoyar la interpretación territorial.

4.5.4 Población expuesta y tasas base

La cuantificación de impactos sanitarios necesitó de incorporar la población expuesta y las tasas base de ocurrencia de los eventos en salud. La población fue organizada sobre la misma malla de análisis y luego agregada en los niveles territoriales de interés. Para ello se partió de información demográfica oficial y se garantizó compatibilidad espacial con la uni-

dad de exposición, siguiendo el principio de consistencia entre malla, población e incidencia que exige la lógica de BenMAP-CE (U.S. EPA, 2023). En particular, se emplearon proyecciones demográficas del DANE para la distribución poblacional de Bogotá por localidad (DANE, 2023).

Las tasas base representan la frecuencia esperada del desenlace en ausencia del cambio de exposición evaluado. Su incorporación es fundamental porque evita interpretar el efecto del contaminante únicamente desde la concentración: una misma variación en exposición no implica el mismo cambio en eventos si la población afectada o la frecuencia basal del desenlace son distintas. Por ello, el módulo sanitario fue construido de forma que cada *endpoint* combinara explícitamente el componente ambiental con el componente epidemiológico y demográfico.

4.5.5 Valoración económica en COP de 2015

Una vez estimados los cambios en eventos de salud, se procedió a su valoración económica mediante funciones específicas por desenlace, siguiendo la lógica de valoración utilizada por BenMAP-CE. En términos generales, el valor económico total asociado a un *endpoint* se obtuvo multiplicando el cambio estimado en eventos por un valor monetario unitario por caso:

$$VE_{i,e} = \Delta Y_{i,e} \times V_e, \quad (4.11)$$

donde $VE_{i,e}$ es el valor económico asociado al desenlace e en la celda i , $\Delta Y_{i,e}$ es el cambio esperado en eventos y V_e corresponde al valor monetario unitario del *endpoint*.

La valoración se expresó en pesos colombianos (COP) de 2015 para mantener homogeneidad entre contaminantes y desenlaces dentro de la corrida base. Esta etapa no debe tomar como una monetización exhaustiva de todos los costos sociales de la contaminación, sino como una traducción comparable de los efectos sanitarios retenidos a una métrica económica común. En BenMAP-CE, esta operación hace parte del componente de agregación, *pooling* y valoración, que permite pasar de resultados brutos de incidencia a estimaciones monetarias comparables y exportables (U.S. EPA, 2023). En el contexto colombiano, trabajos previos como el de Ramírez et al. (2013) ya habían mostrado la pertinencia de este tipo de valoración

espacialmente desagregada para Bogotá.

4.5.6 Agregación espacial y productos de salida

El módulo produjo inicialmente resultados a nivel de celda, tanto para casos evitados como para valor económico. Posteriormente, estos resultados se agregaron por localidad con el fin de facilitar la lectura territorial del beneficio sanitario y monetario. Esta etapa de agregación fue importante porque permitió pasar de una estimación fina sobre la malla a un nivel territorial interpretable para el análisis urbano. La agregación territorial también es consistente con la arquitectura de BenMAP-CE, que distingue entre resultados brutos de incidencia, resultados agregados y resultados valorados (U.S. EPA, 2023).

Como productos finales de esta etapa se obtuvieron: i) tablas de casos evitados por contaminante y *endpoint*, ii) tablas de valoración económica en COP de 2015, iii) resultados desagregados por celda, y iv) resultados agregados por localidad. Estos insumos constituyeron la base directa de la corrida sanitaria y económica presentada en el capítulo de resultados y, además, sirvieron como referencia para los ejercicios de sensibilidad desarrollados posteriormente.

4.6 Análisis de sensibilidad

El análisis de sensibilidad se incorporó como la etapa final del flujo metodológico, con el propósito de evaluar en qué medida las estimaciones sanitarias y económicas dependen de los supuestos utilizados para construir los escenarios de exposición.

A diferencia de una validación predictiva, cuyo interés principal es medir qué tan bien el modelo reproduce los datos observados, el análisis de sensibilidad se centró en cuantificar la variación de los resultados finales cuando cambia la superficie de exposición empleada en el módulo sanitario y económico. Desde esta perspectiva, la sensibilidad permitió interpretar los casos evitados y la valoración económica como resultados condicionados por la construcción del escenario, y no como valores únicos e invariantes.

En términos operativos, se implementaron dos ejercicios principales de sensibilidad. El primero correspondió a la sensibilidad asociada al HBM y consistió en comparar tres su-

perfiles derivadas de la distribución posterior: un escenario bajo representado por el percentil $p05$, un escenario central representado por el percentil $p50$ y un escenario alto representado por el percentil $p95$. Esta formulación permitió evaluar cómo cambia la estimación sanitaria cuando la exposición se aproxima mediante una superficie conservadora, una central o una intensificada, manteniendo fijo el resto de los insumos del módulo sanitario y económico.

El segundo ejercicio corresponde a la sensibilidad climática. Para este caso, la variación proviene de aplicar multiplicadores climáticos contrastantes sobre el escenario central para construir configuraciones favorables, centrales y desfavorables. Bajo esta lógica, el análisis buscó establecer si los beneficios sanitarios estimados aumentaban o disminuían cuando las condiciones climáticas desplazaban la exposición hacia escenarios menos o más favorables.

Para ambos ejercicios, la comparación se realizó utilizando dos métricas complementarias. La primera fue el cambio absoluto de casos evitados frente al escenario central:

$$\Delta CE_{s,e} = CE_{s,e} - CE_{c,e}, \quad (4.12)$$

donde $\Delta CE_{s,e}$ representa el cambio absoluto en casos evitados para el escenario s y el *endpoint* e , $CE_{s,e}$ es el número estimado de casos evitados bajo el escenario alternativo y $CE_{c,e}$ corresponde al valor del escenario central.

La segunda métrica fue la razón relativa frente al escenario central:

$$R_{s,e} = \frac{CE_{s,e}}{CE_{c,e}}, \quad (4.13)$$

donde $R_{s,e}$ mide la proporción del resultado alternativo respecto al escenario central. Valores superiores a 1 indican un aumento de los casos evitados frente al escenario de referencia, mientras que valores inferiores a 1 representan una reducción relativa.

Finalmente, los resultados del análisis de sensibilidad se reportaron en términos sanitarios y, cuando correspondió, en términos económicos. Esta salida permitió comparar no solo la magnitud del cambio en casos evitados, sino también su traducción monetaria bajo una métrica homogénea. De esta manera, la sensibilidad quedó integrada al flujo general del estudio

como una etapa de evaluación de robustez sobre los productos obtenidos tras la modelación espacio-temporal y la corrida base sanitaria y económica.

Capítulo 5

RESULTADOS

5.1 Caracterización inicial del área de estudio y de los campos de concentración

La primera etapa del análisis consistió en definir la base espacial y observacional sobre la cual se construyeron los resultados posteriores. Para ello, el dominio de estudio se representó mediante una malla regular de 3×3 km sobre Bogotá D.C., integrada con la delimitación urbana y la ubicación de las estaciones de monitoreo. Esta definición permitió trabajar con una unidad espacial común para la agregación, la interpolación y la comparación de los resultados a lo largo del periodo 2020–2024.

Como se observa en la Figura 5.1, la red de monitoreo se concentró principalmente en el norte, centro y occidente de la ciudad, mientras que en la franja sur y en las zonas de borde la cobertura instrumental fue menor. En consecuencia, la densidad de información disponible no fue homogénea en todo el territorio, aspecto que debe tenerse en cuenta al interpretar los patrones espaciales obtenidos a partir de la interpolación.

Mapa base del estudio: Bogotá, estaciones de monitoreo y malla regular de 3 km




Figura 5.1. Mapa base del estudio: Bogotá D.C., estaciones de monitoreo y malla regular de 3 km.

Elaboración propia

Una vez definida la estructura espacial, se revisó la calidad general de la base de datos, en particular su completitud y cobertura temporal. La Figura 5.2 muestra el porcentaje de valores faltantes por variable numérica. El principal vacío correspondió a la variable de presión, con un faltante del 100 %. En contraste, las demás variables meteorológicas complementarias presentaron disponibilidad prácticamente completa. Entre los contaminantes criterio, $PM_{2.5}$ registró el menor porcentaje de faltantes, con apenas 0.7 %, mientras que NO_2 y O_3 presentaron faltantes moderados de 13.2 % y 16.7 %, respectivamente. En conjunto, estos resultados indican que la base observacional fue adecuada para el análisis, aunque con distinta solidez según contaminante.




Figura 5.2. Porcentaje de valores faltantes por variable numérica.

Elaboración propia

La cobertura mensual de registros no nulos por contaminante, presentada en la Figura 5.3, complementa esta lectura. PM_{2.5} mantuvo la mayor disponibilidad durante casi todo el periodo 2020–2024, con valores entre 12 y 16 registros por mes. NO₂ comenzó con una cobertura más baja en 2020, cercana a 8 registros mensuales, pero posteriormente mostró una recuperación y estabilización entre 12 y 14 registros. Por su parte, O₃ presentó la menor cobertura relativa, con valores usualmente entre 10 y 13 registros mensuales. En términos generales, la base temporal fue suficientemente estable para el análisis mensual, aunque el soporte empírico fue más robusto para PM_{2.5} y relativamente más limitado para O₃.




Figura 5.3. Cobertura mensual de registros no nulos por contaminante.

Elaboración propia

Después de revisar la completitud de la información, se analizaron los niveles observados de concentración. La Figura 5.4 muestra que $PM_{2.5}$ presentó los promedios anuales observados más altos durante todo el periodo de estudio, con valores aproximados entre 15.4 y 16.9. Este contaminante descendió en 2021, repuntó en 2022, volvió a reducirse en 2023 y aumentó nuevamente en 2024. En el caso de NO_2 , se observó una trayectoria ascendente entre 2020 y 2022, seguida de una leve disminución en 2023 y de una recuperación posterior en 2024. A diferencia de los anteriores, O_3 mostró una reducción entre 2020 y 2022, con recuperación parcial en 2023 y 2024, aunque sin alcanzar completamente el nivel inicial del periodo.




Figura 5.4. Promedios anuales observados de concentración por contaminante (2020–2024).

Elaboración propia

La Figura 5.5 resume la distribución de concentraciones observadas por contaminante. $PM_{2.5}$ exhibió la mayor dispersión y la presencia más marcada de valores extremos altos, lo que sugiere episodios más intensos y una variabilidad considerable. NO_2 presentó una dispersión intermedia, con una distribución amplia pero menos extrema. En contraste, O_3 mostró una mediana menor y una dispersión relativamente más contenida, aunque con algunos valores atípicos. Esta comparación confirma que los tres contaminantes difieren no solo en sus niveles medios, sino también en su estabilidad y rango de variación.




Figura 5.5. Distribución de concentraciones observadas por contaminante.

Elaboración propia

Con base en esta información observacional, se construyeron los campos interpolados sobre la malla regular. La Figura 5.6 presenta los promedios interpolados por celda para $\text{PM}_{2.5}$, NO_2 y O_3 durante el periodo 2020–2024. Los resultados muestran que la interpolación conservó contrastes espaciales dentro del dominio y no produjo una superficie completamente uniforme. En $\text{PM}_{2.5}$ se aprecian máximos relativos más notorios en sectores del norte y noroccidente, junto con valores menores hacia parte del extremo norte y del corredor centro-oriental. En NO_2 también se identifican máximos en la franja noroccidental y central, mientras que en el resto de la malla predominan niveles intermedios. Para O_3 , la distribución fue más homogénea a escala general, aunque persistieron focos de mayor concentración relativa hacia el occidente y reducciones locales en algunas celdas del eje centro-oriental.




Figura 5.6. Promedios interpolados por celda para $\text{PM}_{2.5}$, NO_2 y O_3 en el periodo 2020–2024.

Elaboración propia

Finalmente, la Figura 5.7 muestra la evolución mensual del promedio interpolado sobre la malla. Esta serie es consistente con el comportamiento observado en la información de base. $\text{PM}_{2.5}$ presentó la mayor amplitud temporal y los episodios mensuales más intensos, lo que refuerza su mayor variabilidad espacio-temporal. NO_2 mostró oscilaciones más moderadas y una trayectoria relativamente estable alrededor de valores intermedios-altos. Por su parte, O_3 mantuvo niveles menores y una variación temporal menos pronunciada, aunque con algunos repuntes puntuales. En conjunto, estos resultados indican que el estudio parte de una base observacional consistente y de superficies interpoladas que conservan diferencias espaciales plausibles entre contaminantes, lo que proporciona un soporte adecuado para los análisis posteriores.




Figura 5.7. Promedio mensual del campo interpolado por contaminante.

Elaboración propia

5.1.1 Evidencia de autocorrelación espacial global en los campos interpolados

Como verificación previa a la modelación espacial, se evaluó la autocorrelación global de los campos interpolados mediante el índice de Moran. Este análisis permitió establecer si las concentraciones medias por celda presentaban dependencia espacial sistemática sobre la malla regular, condición relevante para justificar la incorporación de estructura espacial en la etapa posterior de modelación jerárquica bayesiana.

La Figura 5.8 muestra que los tres contaminantes presentaron valores positivos y estadísticamente significativos del índice de Moran. El mayor valor se observó en $PM_{2.5}$ ($I = 0.879$), seguido de O_3 ($I = 0.792$) y NO_2 ($I = 0.708$). En los tres casos, la significancia obtenida por permutaciones fue $p = 0.001$, lo que indica que la estructura espacial observada difícilmente puede atribuirse al azar.

En términos sustantivos, estos resultados muestran que las celdas vecinas tienden a registrar concentraciones semejantes y que los patrones espaciales no corresponden a una distribución aleatoria sobre la malla. Desde el punto de vista metodológico, esta evidencia respalda el uso de una modelación con componente espacial explícito, al confirmar que la información disponible presenta dependencia entre unidades contiguas y no un comportamiento espacialmente independiente.




Figura 5.8. Índice de Moran global de los campos interpolados para PM_{2.5}, NO₂ y O₃.

Elaboración propia

5.1.2 Validación del campo interpolado mediante leave-one-out

Como verificación complementaria de los campos interpolados, se realizó una validación cruzada tipo *leave-one-out* sobre la red de estaciones. En cada iteración, se excluyó una estación y su concentración mensual se estimó a partir de las demás mediante interpolación IDW. Este ejercicio permitió contrastar los valores observados y predichos, con el fin de evaluar si la interpolación conservó la estructura general de la señal empírica de cada contaminante.

La Figura 5.9 resume la comparación punto a punto entre observaciones y predicciones. En los tres contaminantes se identificó una relación positiva entre ambas magnitudes, lo que indica que la interpolación reprodujo adecuadamente la tendencia general de los datos. No obstante, el ajuste no fue homogéneo. En PM_{2.5}, la correspondencia fue razonable, aunque con mayor dispersión en concentraciones medias y altas. En NO₂, las predicciones tendieron a concentrarse en rangos intermedios, sugiriendo un efecto de suavización. En O₃, la relación positiva también se mantuvo, pero con una dispersión relativamente mayor y una menor capacidad para reproducir valores extremos.




Figura 5.9. Validación leave-one-out de los campos interpolados: comparación entre valores observados y predichos para $PM_{2.5}$, NO_2 y O_3 . La línea punteada representa la recta de igualdad.

Elaboración propia

La lectura puntual se complementó con la comparación de las series mensuales agregadas observadas y predichas (Figura 5.10). En términos generales, la interpolación logró seguir la evolución temporal media de los tres contaminantes. Sin embargo, también aquí se observó un patrón de suavización: varios ascensos y descensos mensuales fueron reproducidos con menor amplitud, especialmente en NO_2 y O_3 . En $PM_{2.5}$, la trayectoria general se conservó de forma aceptable, aunque algunos episodios intensos quedaron atenuados.




Figura 5.10. Comparación entre series mensuales agregadas observadas y predichas mediante IDW para $PM_{2.5}$, NO_2 y O_3 .

Elaboración propia

En conjunto, la validación leave-one-out indica que los campos interpolados conservaron la estructura general de variación espacial y temporal de los contaminantes. Aunque el IDW introdujo cierto suavizamiento, especialmente en los valores extremos, los resultados respaldan su uso como insumo espacial previo para la etapa posterior de modelación jerárquica bayesiana.

Implicaciones de la representatividad del campo interpolado. Los resultados de la validación del campo interpolado tienen implicaciones directas sobre las etapas poste-

riores del estudio. En la medida en que el campo IDW logró conservar la tendencia general observada en las estaciones y evidenció autocorrelación espacial positiva, se considera que proporciona un soporte razonable para derivar covariables espaciales asociadas al esquema A–D. Sin embargo, el suavizamiento observado en algunos valores extremos indica que estos campos no deben interpretarse como una reconstrucción exacta de episodios locales de alta concentración, sino como una representación agregada y espacialmente continua del comportamiento mensual de los contaminantes.

Esta precisión es relevante porque las variables derivadas del esquema A–D alimentan el modelo jerárquico bayesiano y, posteriormente, las superficies de exposición utilizadas en la evaluación sanitaria y económica. Por tanto, la incertidumbre o pérdida de detalle en el campo interpolado puede trasladarse a la estimación de exposición poblacional, al cálculo de casos atribuibles o evitados y a la valoración económica. En consecuencia, los resultados finales deben entenderse como estimaciones condicionadas por la representatividad espacial de los campos de concentración y no como valores determinísticos libres de incertidumbre.

5.2 Resultados del componente de advección-difusión

Una vez contruidos los campos interpolados sobre la malla regular, se calcularon los términos espaciales empleados para describir la variación local de las concentraciones. Este análisis permitió comparar, entre contaminantes, el grado de contraste entre celdas vecinas, la intensidad de los gradientes espaciales y el comportamiento temporal de los términos asociados a advección y difusión durante el periodo 2020–2024.

Como punto de partida, la Figura 5.11 muestra la distribución del número de vecinas por celda bajo el criterio de contigüidad tipo Queen. La mayor parte de la malla quedó conformada por celdas interiores con alta conectividad, destacándose 119 celdas con 8 vecinas. En menor proporción aparecen celdas con 7 vecinas (38), 5 vecinas (49) y 3 vecinas (42), mientras que los casos con 1 y 6 vecinas fueron poco frecuentes, con solo 3 celdas en cada grupo. Este patrón es consistente con una malla regular recortada por los límites del dominio: las celdas centrales conservan mayor conectividad y las celdas de borde pierden vecinas por efecto de la forma espacial de Bogotá D.C. En consecuencia, los cálculos locales se apoyan en

una estructura espacial sólida, aunque no completamente homogénea en todo el dominio.




Figura 5.11. Distribución del número de vecinas por celda en la malla tipo Queen.

Elaboración propia

La Figura 5.12 presenta la evolución mensual del gradiente espacial promedio por contaminante, expresado en escala por kilómetro. En términos generales, $\text{PM}_{2.5}$ mostró los gradientes más altos y también la mayor variabilidad temporal, con varios picos a lo largo del periodo. NO_2 registró valores intermedios-altos y un comportamiento relativamente más estable desde 2022, mientras que O_3 tendió a presentar gradientes menores durante buena parte de la serie, aunque con algunos incrementos puntuales. En conjunto, esta figura sugiere que $\text{PM}_{2.5}$ y NO_2 conservaron contrastes espaciales más marcados entre celdas vecinas, mientras que O_3 mostró transiciones más suaves en promedio.




Figura 5.12. Promedio mensual del gradiente espacial por contaminante, en escala por kilómetro.

Elaboración propia

La Figura 5.13 resume el comportamiento temporal del proxy advectivo promedio. El patrón general fue similar al observado en el gradiente espacial, aunque con oscilaciones más intensas en algunos tramos. $PM_{2.5}$ alcanzó varios de los picos más altos de la serie, especialmente al inicio del periodo y en momentos puntuales posteriores. NO_2 mostró niveles altos y relativamente persistentes desde 2022, mientras que O_3 volvió a ubicarse, en general, por debajo de los otros dos contaminantes. Este resultado indica que las variaciones espaciales asociadas al componente advectivo fueron comparativamente más fuertes en $PM_{2.5}$ y NO_2 , y más moderadas en O_3 .




Figura 5.13. Promedio mensual del proxy advectivo por contaminante, en escala por kilómetro.

Elaboración propia

Por su parte, la Figura 5.14 presenta el promedio mensual del término difusivo con signo. A diferencia de los indicadores anteriores, aquí los valores oscilaron alrededor de cero durante todo el periodo para los tres contaminantes. Esto muestra que, al agregarse espacialmente, las contribuciones positivas y negativas del término tienden a compensarse. Por ello, esta figura es útil para verificar la ausencia de un sesgo persistente en la dirección del proceso, aunque resulta menos informativa para comparar directamente la intensidad difusiva entre contaminantes.




Figura 5.14. Promedio mensual del término difusivo por contaminante.

Elaboración propia

Para complementar esa lectura, la Figura 5.15 muestra el valor absoluto promedio del término difusivo. Esta transformación permite evaluar la magnitud del fenómeno sin que las diferencias de signo se anulen entre sí. Bajo esta lectura, NO_2 exhibió los niveles más altos y más persistentes durante buena parte del periodo 2022–2024. $\text{PM}_{2.5}$ presentó algunos máximos puntuales incluso superiores, pero con una trayectoria menos sostenida. En contraste, O_3 mostró, en general, magnitudes menores, aunque con episodios temporales de incremento. Por tanto, al considerar la intensidad del término difusivo, NO_2 aparece como el contaminante más consistente, $\text{PM}_{2.5}$ como el más variable y O_3 como el de menor magnitud relativa durante la mayor parte del periodo.




Figura 5.15. Promedio mensual del valor absoluto del término difusivo por contaminante.

Elaboración propia

En síntesis, los resultados del componente de advección-difusión muestran que la malla espacial construida proporciona una base consistente para representar relaciones locales entre celdas y que los tres contaminantes presentan comportamientos diferenciados. $PM_{2.5}$ destacó por su mayor variabilidad y por la presencia de episodios de alta intensidad tanto en gradiente como en advección y difusión absoluta. NO_2 mostró patrones espacialmente activos y más sostenidos en el tiempo, especialmente en el término difusivo absoluto. O_3 , aunque conservó estructura espacial y variación temporal, presentó en promedio señales más moderadas. En conjunto, estos hallazgos indican que los términos derivados de la malla capturan diferencias espacio-temporales plausibles y constituyen un insumo útil para la modelación posterior y el análisis de sensibilidad.

5.3 Resultados del modelo jerárquico bayesiano espacio-temporal

La etapa de modelación jerárquica bayesiana espacio-temporal tuvo como propósito estimar superficies continuas de concentración para $PM_{2.5}$, NO_2 y O_3 sobre la malla regular de 3 km, incorporando de manera explícita la dependencia espacio-temporal y la incertidumbre asociada al proceso de estimación. En esta fase, el ajuste se realizó a partir de paneles observados depurados por contaminante y de un panel completo de malla con covariables

meteorológicas y variables derivadas del esquema de advección–difusión. La evaluación se centró en la capacidad del modelo para reproducir los valores observados, representar la evolución temporal y caracterizar la incertidumbre posterior.

5.3.1 Desempeño predictivo y comportamiento fuera de muestra

La comparación entre valores observados y predichos permite evaluar qué tan bien el modelo reproduce la señal empírica de cada contaminante. En términos generales, el ajuste fue satisfactorio, aunque con diferencias claras entre $PM_{2.5}$, NO_2 y O_3 .

En $PM_{2.5}$ se observó una relación positiva entre observaciones y predicciones, lo que indica que el modelo logró capturar la estructura general de los datos. Sin embargo, la dispersión alrededor de la diagonal de referencia fue relativamente alta, especialmente en concentraciones medias y altas. Esto sugiere que, aunque el modelo representa adecuadamente la tendencia central, tiene más dificultad para reproducir con precisión los episodios extremos.




Figura 5.16. Comparación entre valores observados y predichos para $PM_{2.5}$. La línea punteada representa la recta de igualdad.

Elaboración propia

En NO_2 , la nube de puntos se concentró más cerca de la diagonal, lo que evidencia

un ajuste más consistente. Visualmente, este contaminante mostró el mejor comportamiento predictivo de los tres, con menor dispersión relativa y una correspondencia más clara entre valores observados y estimados.




Figura 5.17. Comparación entre valores observados y predichos para NO₂. La línea punteada representa la recta de igualdad.

Elaboración propia

En O₃, el modelo también reprodujo una relación positiva entre observaciones y predicciones, pero con una mayor concentración de los valores estimados en un rango intermedio. Esto refleja un comportamiento más suavizado, en el que la señal media es captada de forma razonable, aunque con menor capacidad para representar completamente la amplitud de los valores observados más bajos y más altos.

La lectura temporal de estos resultados se complementa con las series mensuales agregadas observadas y predichas. En PM_{2.5}, el modelo siguió la trayectoria general del contaminante, pero con una clara suavización de varios picos y caídas abruptas. Esto confirma que el ajuste reproduce el patrón medio, aunque con menor sensibilidad ante episodios de




Figura 5.18. Comparación entre valores observados y predichos para O₃. La línea punteada representa la recta de igualdad.

Elaboración propia

variación intensa.




Figura 5.19. Comparación entre series mensuales agregadas observadas y predichas para $PM_{2.5}$.

Elaboración propia

En NO_2 , la serie estimada reprodujo con mayor fidelidad la evolución temporal del contaminante. Se identifican de manera razonable los principales ascensos y descensos, con una menor pérdida de amplitud que en los otros contaminantes. Este resultado es consistente con el mejor desempeño visual observado en la comparación punto a punto.




Figura 5.20. Comparación entre series mensuales agregadas observadas y predichas para NO_2 .

Elaboración propia

En O_3 , la serie predicha mantuvo el nivel medio general y parte de la estructura temporal, pero mostró una mayor suavización relativa. En particular, varios máximos y mínimos observados no fueron reproducidos por completo, lo que sugiere una capacidad más limitada para seguir oscilaciones temporales pronunciadas.




Figura 5.21. Comparación entre series mensuales agregadas observadas y predichas para O_3 .

Elaboración propia

En conjunto, los resultados de ajuste indican que el modelo logró representar de forma adecuada la señal general de los tres contaminantes. No obstante, el mejor desempeño global se observó en NO_2 , mientras que $PM_{2.5}$ presentó mayor dispersión y O_3 un comportamiento temporal más suavizado.

5.3.2 Superficies posteriores de concentración

Además del ajuste frente a los datos observados, el modelo permitió obtener una superficie posterior central para cada contaminante. Estas trayectorias resumen la evolución temporal estimada sobre la malla y permiten comparar el comportamiento estructural de las concentraciones una vez incorporada la dependencia espacio-temporal.

En $PM_{2.5}$ se observó la mayor amplitud temporal. La superficie posterior central mostró ascensos y descensos notorios a lo largo del período, lo que es coherente con la mayor variabilidad ya identificada en los resultados previos. Este contaminante conserva una dinámica más marcada y menos estable en el tiempo.

En NO_2 , la superficie posterior central presentó oscilaciones moderadas alrededor de niveles intermedios, con una trayectoria más estable que la observada para $PM_{2.5}$. Este comportamiento refuerza la idea de que el modelo logró capturar de manera más consistente la estructura temporal de este contaminante.

En O_3 , la superficie posterior central mostró una evolución temporal intermedia: se identifican cambios y repuntes puntuales, pero sin alcanzar la amplitud observada en $PM_{2.5}$. En comparación con NO_2 , la trayectoria es menos estable, aunque mantiene una señal interpretable y consistente con el comportamiento general del contaminante.




Figura 5.22. Promedio mensual de la superficie posterior central estimada para PM_{2.5}.

Elaboración propia




Figura 5.23. Promedio mensual de la superficie posterior central estimada para NO₂.

Elaboración propia




Figura 5.24. Promedio mensual de la superficie posterior central estimada para O₃.

Elaboración propia

Estas superficies posteriores muestran que el modelo no solo suaviza el ruido observacional, sino que también conserva diferencias plausibles entre contaminantes. En particular, $PM_{2.5}$ retuvo la mayor amplitud temporal, NO_2 mostró la trayectoria más estable y O_3 mantuvo una señal intermedia con variaciones menos extremas.

5.3.3 Incertidumbre posterior de las estimaciones

La incertidumbre posterior se resumió mediante el ancho promedio del intervalo creíble del 90 %. Esta medida permite evaluar la precisión relativa de las estimaciones y comparar el grado de confianza del modelo entre contaminantes y a lo largo del tiempo.

En $PM_{2.5}$ se registraron, en general, los mayores anchos de intervalo. Además, se observaron episodios específicos de incremento notable en la incertidumbre, lo que indica que este contaminante fue el más difícil de estimar con precisión relativa. Esta lectura es coherente con la mayor dispersión observada en los gráficos de ajuste.




Figura 5.25. Promedio mensual del ancho del intervalo creíble del 90 % para $PM_{2.5}$.

Elaboración propia

En NO_2 , la incertidumbre fue intermedia y mostró una trayectoria relativamente más estable. Aunque hubo fluctuaciones a lo largo del período, los niveles generales de incertidumbre fueron más contenidos que en $PM_{2.5}$, en concordancia con el mejor desempeño predictivo del modelo para este contaminante.

En O_3 , los anchos del intervalo fueron menores que los de $PM_{2.5}$ durante buena parte del período, pero presentaron oscilaciones temporales importantes. Esto sugiere una incertidumbre moderada en promedio, aunque más variable en el tiempo. En otras palabras, el




Figura 5.26. Promedio mensual del ancho del intervalo creíble del 90 % para NO₂.

Elaboración propia

modelo fue relativamente estable para estimar niveles medios de O₃, pero no con la misma regularidad en todos los meses.




Figura 5.27. Promedio mensual del ancho del intervalo creíble del 90 % para O₃.

Elaboración propia

En términos comparativos, la incertidumbre posterior fue mayor en PM_{2.5}, más estable en NO₂ y moderada, aunque más oscilante, en O₃. Esta diferencia entre contaminantes refuerza la necesidad de interpretar las superficies estimadas no solo a partir de su valor central, sino también considerando la precisión con la que fueron obtenidas.

5.3.4 Síntesis de resultados del HBM

En síntesis, el modelo jerárquico bayesiano espacio–temporal permitió reproducir la señal general de los tres contaminantes y construir superficies continuas de concentración coherentes con la dinámica observada en la malla. Sin embargo, el desempeño no fue homo-

géneo entre contaminantes. NO_2 presentó el ajuste más consistente, tanto en la comparación entre valores observados y predichos como en la evolución temporal agregada. $\text{PM}_{2.5}$ conservó una señal plausible, pero con mayor dispersión, mayor dificultad para representar episodios extremos y mayores niveles de incertidumbre posterior. O_3 , por su parte, mostró una capacidad razonable para representar el nivel medio y la estructura general del período, aunque con una mayor suavización temporal y una menor capacidad para reproducir completamente las oscilaciones observadas.

En conjunto, estos resultados respaldan el uso del HBM como herramienta para construir superficies de exposición consistentes y comparables entre contaminantes, al tiempo que ponen en evidencia que el grado de ajuste y la precisión de las estimaciones dependen de la variabilidad propia de cada contaminante y de la complejidad de su comportamiento espacio-temporal.

5.3.5 Implicaciones de la validez de los modelos ambientales sobre la exposición y la valoración económica

La validez de los modelos ambientales empleados en las etapas A–D y HBM tiene implicaciones directas sobre la interpretación de los resultados sanitarios y económicos posteriores. Esto se debe a que el flujo metodológico del estudio sigue una cadena secuencial: primero se construyen campos de concentración, luego se derivan superficies de exposición, posteriormente se estiman cambios esperados en eventos de salud y finalmente se realiza la valoración monetaria. En consecuencia, cualquier incertidumbre o sesgo presente en la etapa ambiental puede trasladarse a las estimaciones de casos evitados y al valor económico asociado.

En el caso del esquema A–D, los resultados respaldan la utilidad como herramienta de caracterización física-operacional ya que los términos de gradiente, difusión y proxy advectivo capturaron diferencias entre contaminantes y permitieron enriquecer la modelación posterior. Sin embargo, debido a que este componente no resuelve de manera completa la ecuación atmosférica de transporte, sus productos no deben interpretarse como campos definitivos de exposición. la función dentro del estudio fue construir covariables auxiliares

con sentido físico, cuyo aporte depende de la representatividad del campo interpolado y de la estructura de vecindad definida sobre la malla.

En el caso del HBM, la validez de las superficies estimadas se apoyó en el uso de observaciones reales de estaciones, la incorporación de efectos espaciales y temporales, la validación fuera de muestra y la cuantificación de incertidumbre posterior. No obstante, los resultados mostraron diferencias entre contaminantes: NO_2 presentó el ajuste más consistente, $\text{PM}_{2.5}$ mostró mayor dispersión e incertidumbre, y O_3 presentó una tendencia a suavizar algunas oscilaciones temporales. Por tanto, las superficies de exposición no tienen el mismo grado de precisión para todos los contaminantes, lo cual debe reflejarse en la interpretación de los resultados sanitarios y económicos.

Esta diferencia es importante para la corrida base. Los casos evitados y los valores económicos obtenidos no deben entenderse como cifras determinísticas, sino como estimaciones condicionadas por la calidad de las superficies de concentración utilizadas como insumo. Así, los resultados asociados a NO_2 pueden interpretarse con mayor estabilidad relativa dentro del marco del modelo, mientras que los resultados asociados a $\text{PM}_{2.5}$ y O_3 deben leerse con mayor cautela, especialmente cuando dependen de episodios extremos o de variaciones temporales que el modelo tiende a suavizar.

Por esta razón, el análisis de sensibilidad adquiere un papel central en la legitimación de los resultados. Al utilizar percentiles posteriores del HBM y escenarios climáticos, el estudio no presenta una única estimación cerrada, sino un conjunto de resultados plausibles bajo distintos supuestos de exposición. Esta estrategia permite reconocer explícitamente que la carga sanitaria y económica atribuible a la contaminación del aire depende de la incertidumbre de los modelos ambientales, de las funciones concentración–respuesta, de la población expuesta, de las tasas base y de los valores monetarios asignados a cada desenlace.

En consecuencia, las conclusiones de la investigación deben formularse de manera condicionada. Los resultados permiten identificar patrones, comparar escenarios y reconocer contaminantes o desenlaces con mayor sensibilidad, pero no deben presentarse como una medición exacta de la carga total real de la contaminación atmosférica en Bogotá. Su aporte principal está en ofrecer una aproximación estructurada, reproducible y sensible a la incer-

tidumbre para evaluar cómo cambios en la calidad del aire pueden traducirse en impactos sanitarios y económicos.

5.4 Resultados de la corrida base sanitaria y económica

La corrida base integró las superficies centrales estimadas mediante el modelo jerárquico bayesiano, las funciones concentración–respuesta seleccionadas y la valoración económica expresada en COP de 2015. Esta etapa permitió resumir, en términos sanitarios y monetarios, los beneficios asociados a los cambios de concentración evaluados para $PM_{2.5}$, NO_2 y O_3 . Los resultados se presentan primero de forma agregada por *endpoint* y luego desde su distribución espacial por localidad.

5.4.1 Resultados agregados por *endpoint*

La Figura 5.28 muestra los casos evitados estimados en la corrida base. El mayor número de casos evitados se obtuvo en los desenlaces asociados a NO_2 , particularmente en hospitalizaciones por asma (12.71) y por enfermedad pulmonar crónica (9.45). En comparación, los resultados agregados para O_3 y $PM_{2.5}$ fueron menores en número de casos, con 2.20 y 1.30, respectivamente. En términos sanitarios, esto indica que dentro del conjunto de *endpoints* evaluados, los efectos cuantificados para NO_2 concentraron la mayor fracción del beneficio en número de eventos evitados.

La lectura económica complementa ese resultado sanitario. Como se observa en la Figura 5.29, los mayores beneficios monetarios de la corrida base correspondieron a los desenlaces de mortalidad. O_3 en mortalidad respiratoria alcanzó 53.22 mil millones de COP de 2015, mientras que $PM_{2.5}$ en mortalidad por todas las causas registró 31.38 mil millones de COP de 2015. Aunque estos dos desenlaces no concentraron el mayor número de casos evitados, sí reunieron la mayor valoración monetaria total, lo que refleja el mayor peso económico asociado a los *endpoints* de mortalidad frente a los de hospitalización.

Por su parte, la Figura 5.30 muestra que los beneficios económicos asociados a hospitalizaciones por NO_2 fueron más modestos en comparación con los de mortalidad, aunque internamente bastante similares entre sí. La hospitalización por enfermedad pulmonar crónica




Figura 5.28. Casos evitados en la corrida base por *endpoint*.

Elaboración propia




Figura 5.29. Valor económico en COP de 2015 para los *endpoints* de mortalidad en la corrida base.

Elaboración propia

alcanzó 403.14 millones de COP de 2015 y la hospitalización por asma 396.04 millones de COP de 2015. En consecuencia, la corrida base sugiere que NO₂ fue el contaminante con mayor aporte en número de eventos evitados dentro de los desenlaces incluidos, mientras que la mayor contribución económica total estuvo asociada a los efectos de mortalidad de O₃ y PM_{2.5}.




Figura 5.30. Valor económico en COP de 2015 para los *endpoints* de hospitalización en la corrida base.

Elaboración propia

5.4.2 Distribución espacial del valor económico por localidad

Además del resultado agregado por contaminante y desenlace, la corrida base permitió identificar cómo se distribuye el valor económico entre localidades. En las cuatro corridas evaluadas, Sumapaz apareció como la localidad con mayor participación agregada, con valores cercanos al 47 % del total. Sin embargo, este resultado debe interpretarse con cautela, dado que esta localidad tiene una extensión territorial considerablemente mayor dentro de la malla de análisis y concentra una proporción elevada de las celdas intersectadas. Por tanto, su predominio en los valores agregados no debe entenderse como evidencia directa de una mayor carga individual de morbilidad, sino como un resultado condicionado por el procedimiento de agregación espacial.

Con el fin de facilitar la lectura del patrón urbano entre las demás localidades, la Figura 5.31 presenta la participación del valor económico excluyendo Sumapaz únicamente

con fines de visualización. Es importante señalar que los porcentajes no fueron recalculados después de excluir esta localidad; por tanto, cada barra conserva como denominador el total original de la corrida correspondiente. Bajo esta lectura, Usme aparece como la localidad con mayor participación relativa entre las localidades urbanas, seguida por Ciudad Bolívar, Suba, Usaquén, San Cristóbal y Santa Fe. Este patrón se mantiene de forma consistente en los *endpoints* evaluados, lo que sugiere que, una vez controlado el efecto visual de Sumapaz, la distribución territorial del valor económico conserva una estructura estable entre contaminantes y desenlaces.




Figura 5.31. Participación del valor económico por localidad, excluyendo Sumapaz para fines de visualización. Los porcentajes se calcularon respecto al total original de cada corrida, por lo que la exclusión no modifica el denominador del análisis. Elaboración propia.

Elaboración propia

Nota. Sumapaz se excluye únicamente de la visualización principal debido a su peso espacial desproporcionado dentro de la malla de análisis. La localidad sí fue incluida en los cálculos originales y se conserva en las tablas completas, anexos y repositorio del proyecto.

En términos generales, la distribución espacial del valor económico muestra que los resultados no se reparten de forma homogénea entre las localidades urbanas. En los cuatro

escenarios de la corrida base, Usme concentra la mayor participación relativa dentro del conjunto visualizado, con valores cercanos al 13 %, mientras que Ciudad Bolívar se ubica en segundo lugar, con participaciones cercanas al 8 %. Suba ocupa una posición intermedia, con participaciones alrededor del 6 %, y luego aparecen Usaquén, San Cristóbal y Santa Fe con contribuciones menores, pero recurrentes en todos los *endpoints*. Esta regularidad indica que la estructura territorial de los beneficios monetarios estimados no depende únicamente del contaminante o del desenlace específico, sino también de la forma en que las superficies de exposición, la población objetivo y las funciones concentración–respuesta se combinan espacialmente.

En síntesis, los resultados de la corrida base muestran dos hallazgos principales. En primer lugar, los mayores beneficios sanitarios en número de casos evitados se concentraron en los *endpoints* de hospitalización asociados a NO₂. En segundo lugar, los mayores beneficios económicos correspondieron a los desenlaces de mortalidad asociados a O₃ y PM_{2.5}. Desde el punto de vista espacial, los resultados agregados por localidad evidencian una concentración territorial importante; no obstante, la participación dominante de Sumapaz debe interpretarse como un efecto condicionado por la agregación espacial sobre la malla y no como una mayor carga individual de morbilidad. Por ello, la visualización principal se enfoca en el patrón urbano sin Sumapaz, mientras que los resultados completos se mantienen documentados en los anexos y en el repositorio del proyecto.

5.5 Resultados del análisis de sensibilidad

El análisis de sensibilidad permitió evaluar qué tanto cambian los beneficios sanitarios estimados cuando se modifican algunos supuestos clave del ejercicio base. En esta etapa se consideraron, por una parte, variaciones asociadas al escenario derivado del modelo jerárquico bayesiano y, por otra, cambios vinculados a escenarios climáticos contrastantes. Los resultados se presentan en términos comparativos frente al escenario central, con énfasis en el número de casos evitados y en la magnitud relativa de las variaciones observadas.

5.5.1 Sensibilidad asociada al escenario derivado del HBM

La Figura 5.32 resume el cambio absoluto en los casos evitados cuando se comparan los escenarios alto y bajo frente al escenario central derivado del HBM. En todos los *end-points*, el escenario alto produjo incrementos en los casos evitados, mientras que el escenario bajo generó reducciones respecto al caso central. Este comportamiento era esperable, ya que una mayor superficie de exposición implica un efecto sanitario más intenso y, en sentido contrario, una superficie más baja reduce el beneficio estimado.

Además, la magnitud del cambio no fue homogénea entre desenlaces. Los mayores desplazamientos absolutos se observaron en los *endpoints* asociados a NO₂, especialmente en asma y enfermedad pulmonar crónica, lo que indica que estos resultados son más sensibles a cambios en la superficie de concentración utilizada como insumo. En contraste, los cambios fueron más moderados para O₃ y particularmente menores para PM_{2.5}, lo que sugiere una respuesta sanitaria relativamente más estable frente a este tipo de variación.




Figura 5.32. Cambio absoluto de casos evitados frente al escenario central en la sensibilidad asociada al HBM.

Elaboración propia

5.5.2 Sensibilidad asociada a escenarios climáticos

La Figura 5.33 presenta la razón de casos evitados frente al escenario central bajo dos configuraciones climáticas contrastantes. En términos generales, el escenario desfavorable se ubicó por encima de la unidad en todos los *endpoints*, mientras que el escenario favorable se situó por debajo de ese valor. Esto indica que, bajo condiciones climáticas menos favorables, los beneficios sanitarios estimados aumentan respecto al escenario central, mientras que bajo condiciones favorables dichos beneficios tienden a disminuir.

Aunque la dirección del efecto fue consistente, la intensidad del cambio difirió entre desenlaces. Los resultados asociados a O₃ mostraron la mayor separación respecto al escenario central, seguidos por PM_{2.5}, mientras que los *endpoints* vinculados a NO₂ presentaron variaciones relativamente menores. Esta lectura se refuerza en la Figura 5.34, donde la amplitud relativa total del cambio fue más alta para O₃, intermedia para PM_{2.5} y más reducida para los dos desenlaces asociados a NO₂.

En conjunto, estos resultados indican que la sensibilidad climática no es uniforme entre contaminantes. En particular, O₃ aparece como el contaminante más sensible a la modificación del escenario climático, mientras que NO₂ presenta una respuesta más contenida. Esto es relevante porque muestra que la incertidumbre asociada a condiciones climáticas puede alterar de manera diferenciada la magnitud de los beneficios sanitarios estimados.




Figura 5.33. Razón de casos evitados frente al escenario central en la sensibilidad climática.

Elaboración propia




Figura 5.34. Amplitud relativa total del cambio en casos evitados bajo sensibilidad climática.

Elaboración propia

5.5.3 Síntesis de los resultados de sensibilidad

En síntesis, el análisis de sensibilidad mostró que los beneficios sanitarios estimados dependen de manera apreciable de los supuestos utilizados para construir los escenarios de exposición. Las variaciones derivadas del HBM afectaron con mayor fuerza los desenlaces asociados a NO_2 , mientras que la sensibilidad climática resultó más marcada para O_3 . Por su parte, $\text{PM}_{2.5}$ mostró un comportamiento intermedio en los análisis climáticos y cambios más moderados en la sensibilidad asociada al HBM.

Estos hallazgos confirman que la magnitud de los casos evitados no debe interpretarse como un valor único e invariable, sino como una estimación condicionada por decisiones metodológicas y por la configuración de los escenarios analizados. En consecuencia, la incorporación explícita de sensibilidad fortalece la interpretación de los resultados y aporta mayor solidez al análisis final del estudio.

Cuadro 5.1. Resumen de hallazgos principales del análisis.

Componente	Resultado obtenido
Base observacional y fases A–D	La cobertura disponible permitió desarrollar un análisis mensual, aunque no fue homogénea entre contaminantes ni en todo el territorio de análisis. Los indicadores de gradiente, difusión y proxy advectivo capturaron diferencias espacio–temporales plausibles entre contaminantes.
Modelo HBM	NO ₂ presentó el ajuste más estable; PM _{2.5} mostró mayor dispersión e incertidumbre posterior; y O ₃ reprodujo la señal media general, aunque con suavizamiento temporal frente a oscilaciones más pronunciadas.
Carga sanitaria y económica	NO ₂ concentró el mayor número de casos evitados en desenlaces de hospitalización, mientras que O ₃ y PM _{2.5} explicaron los mayores valores monetarios en los <i>endpoints</i> de mortalidad.
Distribución territorial	Sumapaz debe interpretarse con cautela por su peso espacial dentro de la malla. En la lectura urbana, las localidades que aparecen de forma recurrente son Usme, Ciudad Bolívar, Suba, Usaquén, San Cristóbal y Santa Fe.
Sensibilidad	Las variaciones del HBM impactaron especialmente los <i>endpoints</i> asociados a NO ₂ , mientras que los escenarios climáticos afectaron con mayor fuerza relativa a O ₃ . En conjunto, los resultados deben comunicarse como estimaciones condicionadas por escenarios, supuestos e incertidumbre.

Nota. La tabla sintetiza los principales resultados obtenidos en las etapas de caracterización, modelación, corrida base y análisis de sensibilidad. Elaboración propia.

Capítulo 6

DISCUSIÓN

Los resultados a lo largo de este trabajo muestran que la combinación de un esquema físico-operacional basado en principios de advección–difusión, un modelo jerárquico bayesiano espacio–temporal y un módulo sanitario-económico inspirado en BenMAP-CE constituye una ruta metodológica útil para evaluar impactos de calidad del aire bajo incertidumbre. El principal aporte del estudio no consiste únicamente en estimar concentraciones, casos evitados o valores económicos, sino en construir un flujo reproducible que conecta exposición ambiental, variabilidad espacial, incertidumbre posterior y valoración sanitaria y económica.

Desde el componente físico-operacional, el esquema A–D permitió transformar una formulación conceptual del balance de masa en variables concretas sobre la malla de análisis. Los indicadores de difusión, gradiente y proxy advectivo aportaron información sobre contraste local, heterogeneidad espacial y potencial de transporte. Sin embargo, su interpretación debe mantenerse dentro del alcance metodológico definido: no se trata de una simulación determinística completa de dispersión atmosférica, sino de una aproximación discreta para generar covariables físicamente interpretables. Por tanto, su validez se relaciona con la coherencia y trazabilidad de los campos derivados, no con la reproducción exacta de todos los procesos atmosféricos urbanos.

Desde el componente bayesiano, el HBM permitió estimar superficies espacio–temporales continuas de concentración incorporando dependencia espacial, evolución

temporal e incertidumbre posterior. La comparación entre contaminantes evidenció que la validez del modelo no fue homogénea. NO₂ presentó el desempeño más consistente, tanto en la comparación entre observaciones y predicciones como en la evolución temporal agregada. PM_{2.5} mostró una señal plausible, pero con mayor dispersión, mayor incertidumbre y menor capacidad para capturar episodios extremos. O₃ reprodujo el nivel medio general, aunque con suavizamiento de algunas oscilaciones temporales. Esta diferencia implica que los resultados posteriores deben interpretarse con distinto grado de confianza según el contaminante.

La validez de los modelos ambientales condiciona directamente la etapa sanitaria y económica. En este estudio, las superficies de concentración funcionan como insumo para calcular cambios de exposición; esos cambios se combinan con población, tasas base y funciones concentración–respuesta para estimar eventos de salud; y posteriormente dichos eventos se traducen a valores monetarios. Por ello, los resultados de carga sanitaria y económica no pueden separarse de la incertidumbre del modelo ambiental que los alimenta. Si una superficie suaviza valores extremos o tiene menor representatividad en ciertas zonas, las estimaciones de casos evitados y de valoración económica asociadas también deben leerse con cuidado.

Desde el punto de vista sanitario, los resultados muestran que el número de casos evitados y el valor económico no necesariamente siguen la misma jerarquía. Los *endpoints* asociados a NO₂ aportaron más casos evitados, especialmente en hospitalizaciones; sin embargo, los mayores beneficios económicos correspondieron a mortalidad por O₃ y PM_{2.5}. Esto indica que la interpretación de los beneficios de calidad del aire debe considerar simultáneamente la frecuencia del evento, la gravedad del desenlace, la población expuesta y el valor económico unitario asignado.

La lectura espacial también requiere de un análisis cuidadoso. La participación agregada de Sumapaz no debe interpretarse automáticamente como mayor riesgo individual, sino como un efecto condicionado por su extensión territorial y por el número de celdas que aporta a la agregación. Por esta razón, los resultados por localidad deben complementarse en trabajos futuros con métricas normalizadas, como casos por 100.000 habitantes, valor económico por habitante o resultados restringidos al suelo urbano. Esta precisión es importante para evitar conclusiones territoriales sobredimensionadas por el tamaño espacial de la unidad de análisis.

Finalmente, el análisis de sensibilidad confirma que las estimaciones dependen de los supuestos empleados para construir las superficies de exposición. La incertidumbre no se propaga igual entre contaminantes ni entre *endpoints*: las variaciones asociadas al HBM afectaron con mayor fuerza los desenlaces vinculados a NO₂, mientras que los escenarios climáticos modificaron con mayor intensidad relativa los beneficios estimados para O₃. En consecuencia, los resultados deben presentarse como escenarios plausibles bajo supuestos explícitos y no como cifras únicas definitivas. Esta forma de interpretación fortalece el alcance del trabajo, porque reconoce las limitaciones de los modelos y evita convertir estimaciones condicionadas en afirmaciones absolutas.

6.1 CONCLUSIONES

El estudio permitió construir una ruta metodológica integrada para estimar cargas sanitarias y económicas atribuibles a cambios en la calidad del aire en Bogotá, articulando un esquema físico-operacional basado en principios de advección–difusión, un modelo jerárquico bayesiano espacio–temporal y un módulo computacional inspirado en la lógica de BenMAP-CE. Esta integración permitió pasar de mediciones observadas e interpoladas a superficies de exposición, estimaciones de casos evitados, valoración económica y análisis de sensibilidad bajo distintos supuestos de incertidumbre.

El componente de advección–difusión aportó una base física-operacional para caracterizar contrastes espaciales, gradientes locales y potencial de transporte de los contaminantes sobre la malla de 3 km × 3 km. Sin embargo, su alcance debe entenderse de manera delimitada: no corresponde a una simulación determinística completa de dispersión atmosférica, sino a una aproximación discreta para construir covariables con interpretación física. En este sentido, su principal contribución fue enriquecer la modelación estadística posterior y no reemplazar un modelo atmosférico físico-químico completo.

Para los resultados del modelo jerárquico bayesiano, mostraron que los contaminantes analizados presentan comportamientos espacio–temporales diferenciados. NO₂ tuvo el ajuste más estable y una incertidumbre posterior relativamente más contenida, lo que permite interpretar sus superficies estimadas con mayor confianza relativa dentro del marco del modelo.

PM_{2.5} presentó mayor dispersión, mayor dificultad para capturar episodios extremos y mayor incertidumbre posterior. O₃ fue representado adecuadamente en su tendencia media, aunque con suavizamiento de algunas oscilaciones temporales. Por tanto, la validez de las superficies de exposición no fue homogénea entre contaminantes y esta diferencia debe considerarse al interpretar los resultados sanitarios y económicos.

En la corrida base, los mayores beneficios en número de eventos evitados se asociaron a los *endpoints* de hospitalización vinculados con NO₂, mientras que los mayores beneficios monetarios correspondieron a desenlaces de mortalidad asociados con O₃ y PM_{2.5}. Este contraste evidencia que la priorización de impactos no debe basarse únicamente en el número de casos, sino también en la gravedad del desenlace, la población expuesta, la función concentración–respuesta utilizada y el valor monetario unitario asignado.

La distribución territorial de los beneficios estimados evidenció heterogeneidad espacial entre localidades. No obstante, los resultados agregados deben interpretarse con cautela, especialmente en el caso de Sumapaz, cuyo peso se explica principalmente por su extensión territorial y por el número de celdas que aporta a la malla. En consecuencia, las comparaciones territoriales deben considerar no solo valores absolutos, sino también métricas normalizadas que permitan diferenciar entre magnitud agregada, exposición poblacional y riesgo relativo.

El análisis de sensibilidad constituye uno de los aportes centrales del trabajo, ya que mostró que las cargas sanitarias y económicas estimadas dependen de manera importante de los supuestos empleados para construir las superficies de exposición y los escenarios de análisis. Las variaciones derivadas del HBM afectaron especialmente los resultados asociados a NO₂, mientras que los escenarios climáticos modificaron con mayor intensidad relativa los resultados vinculados a O₃. Esto confirma que las estimaciones no deben interpretarse como cifras únicas o determinísticas, sino como resultados condicionados por la incertidumbre del modelo ambiental, las funciones concentración–respuesta, las tasas base, la población expuesta y los parámetros de valoración económica.

En conjunto, la investigación aporta una aproximación reproducible y sensible a la incertidumbre para evaluar impactos sanitarios y económicos asociados a la calidad del aire en

Bogotá. Sus resultados permiten identificar patrones relevantes y comparar escenarios, pero deben entenderse como estimaciones condicionadas por los datos disponibles, la representatividad espacial de la red de monitoreo y las decisiones metodológicas adoptadas durante la modelación.

Capítulo 7

LIMITACIONES DEL ESTUDIO

La primera limitación corresponde a la cobertura y distribución espacial de la red de monitoreo. Aunque la información disponible permitió construir series mensuales y superficies de concentración para $PM_{2.5}$, NO_2 y O_3 , la ubicación de las estaciones no es homogénea dentro del dominio de Bogotá. Algunas zonas periféricas y de borde cuentan con menor soporte observacional, lo que puede afectar la precisión de las interpolaciones y de las superficies posteriores en esas áreas. Esta limitación es especialmente relevante para contaminantes con menor disponibilidad relativa de datos, como O_3 .

Una segunda limitación se relaciona con el alcance del esquema de advección–difusión. En esta investigación, dicho componente se implementó como una aproximación físico-operacional para construir covariables espaciales derivadas, no como una simulación determinística completa de transporte atmosférico. Por tanto, los términos de difusión, gradiente y proxy advectivo no deben interpretarse como flujos físicos exactos, sino como indicadores discretos de contraste espacial, heterogeneidad local y potencial de transporte. La ausencia de información detallada sobre dirección del viento por celda, perfiles verticales, inventarios horarios de emisiones, coeficientes de difusión turbulenta y tasas de reacción o deposición limita la posibilidad de resolver completamente la ecuación física de transporte.

Una tercera limitación se asocia con la construcción de las superficies de exposición. La interpolación IDW y el modelo jerárquico bayesiano permitieron obtener campos continuos y estables sobre la malla de análisis, pero ambos procedimientos pueden suavizar valores

extremos o episodios locales de alta concentración. En consecuencia, las superficies estimadas deben entenderse como representaciones agregadas y probabilísticas de la exposición mensual, no como reconstrucciones exactas de cada episodio atmosférico puntual.

Una cuarta limitación corresponde al desempeño diferencial del modelo jerárquico bayesiano entre contaminantes. Los resultados mostraron que NO_2 presentó un ajuste más estable, mientras que $\text{PM}_{2.5}$ tuvo mayor dispersión e incertidumbre posterior y O_3 mostró cierta tendencia al suavizamiento temporal. Esto se debe tener en cuenta ya que la validez de las superficies generadas no es homogénea para todos los contaminantes. Por tanto, las estimaciones sanitarias y económicas derivadas de cada superficie deben interpretarse considerando el grado de ajuste, incertidumbre y representatividad del contaminante correspondiente.

Una quinta limitación se relaciona con la evaluación sanitaria y económica. Las funciones concentración–respuesta, las tasas base y los parámetros de valoración monetaria provienen de fuentes secundarias y pueden no representar completamente las condiciones epidemiológicas, sociales y económicas actuales de Bogotá. Además, el análisis incluyó un conjunto acotado de *endpoints*, por lo que la carga total atribuible a la contaminación del aire podría estar subestimada.

Una sexta limitación corresponde a la agregación espacial de los resultados. Los valores por localidad dependen del tamaño de la malla, de la intersección de celdas con cada unidad territorial y de la extensión espacial de cada localidad. Esto explica el peso agregado de Sumapaz dentro de los resultados, el cual no debe interpretarse necesariamente como mayor riesgo individual. Para comparaciones territoriales más precisas, sería necesario complementar los resultados absolutos con indicadores normalizados por población, área o densidad de exposición.

Finalmente, los escenarios climáticos utilizados en el análisis de sensibilidad deben interpretarse como ejercicios exploratorios y no como proyecciones atmosféricas completas. Su objetivo fue evaluar la respuesta de las cargas sanitarias y económicas ante cambios plausibles en las superficies de exposición, pero no sustituir una modelación climática regional ni una simulación físico-química de calidad del aire bajo escenarios futuros.

Capítulo 8

RECOMENDACIONES Y TRABAJO FUTURO

A partir del desarrollo del estudio, se recomienda fortalecer la gestión, estandarización y trazabilidad de los datos ambientales, demográficos y sanitarios utilizados en evaluaciones de calidad del aire. Para ello, resulta necesario avanzar hacia bases de datos más integradas, con criterios homogéneos de identificación espacial, temporalidad, unidades de medida, control de calidad, documentación de metadatos y disponibilidad histórica. Una mejor gestión de la información por parte de los actores responsables de su producción y administración permitiría reducir reprocesamientos, mejorar la comparabilidad entre fuentes y facilitar la construcción de análisis reproducibles para apoyar decisiones en salud ambiental.

También se recomienda mejorar la calidad, cobertura y continuidad de la red de monitoreo de calidad del aire. Esto implica no solo aumentar la densidad de medición en zonas con menor representación espacial, sino también asegurar mayor estabilidad temporal en los registros, menor proporción de datos faltantes, mejor documentación de cambios operativos y mayor articulación entre estaciones urbanas, periféricas y zonas de borde. Una red más equilibrada permitiría representar con mayor precisión los gradientes intraurbanos de $PM_{2.5}$, NO_2 y O_3 , así como fortalecer los modelos de interpolación, estimación bayesiana y análisis de exposición.

Como línea de trabajo futuro, se recomienda incorporar covariables adicionales que

permitan explicar de manera más completa la variabilidad espacial y temporal de los contaminantes. Además de las variables meteorológicas y de los términos derivados del esquema de advección–difusión, sería pertinente incluir información sobre uso del suelo, intensidad del tráfico, cercanía a fuentes de emisión, densidad poblacional, cobertura vegetal, actividad industrial, condiciones topográficas y características socioeconómicas del territorio. Estas covariables permitirían mejorar la capacidad explicativa de los modelos, diferenciar patrones entre zonas urbanas y rurales, y representar con mayor detalle los factores que condicionan la exposición de la población.

En relación con la modelación, se recomienda profundizar en estrategias de validación que permitan evaluar la capacidad de generalización de los modelos en distintos contextos espaciales y temporales. Para ello, futuros trabajos podrían implementar esquemas de validación cruzada por estación, por localidad, por periodo y por zonas con diferente disponibilidad de información. Asimismo, sería conveniente comparar distintas estructuras de dependencia espacial y temporal, así como contrastar el desempeño del modelo jerárquico bayesiano frente a otros enfoques estadísticos o de aprendizaje automático. Esta validación ampliada permitiría identificar con mayor claridad en qué condiciones los modelos son más robustos y dónde requieren ajustes adicionales.

Finalmente, se recomienda actualizar y contextualizar las funciones sanitarias y económicas utilizadas para estimar impactos en salud y valoración monetaria. En particular, futuros estudios deberían avanzar hacia funciones concentración–respuesta, tasas base, grupos etarios, desenlaces sanitarios y parámetros económicos más acordes con el contexto actual de Colombia. Esta actualización debería considerar diferencias entre población urbana y rural, condiciones socioeconómicas, estructura etaria, acceso a servicios de salud y heterogeneidad territorial. Con ello, las estimaciones de carga sanitaria y económica podrían reflejar de manera más adecuada las condiciones locales y aportar insumos más precisos para la formulación de estrategias de gestión de calidad del aire y protección de la salud pública.

8.1 ANEXOS

todas las imagenes, codigo, tablas, resultados adicionales y/o complementarios se encuentran en el siguiente repositorio: **https://github.com/DrachenDuchy/Analisis_sensibilidad.git**

Bibliografía

- [1] Banerjee, S., Carlin, B. P., & Gelfand, A. E. (2014). *Hierarchical modeling and analysis for spatial data*. Chapman and Hall/CRC.
- [2] Box, G. E. P., Jenkins, G. M., & Reinsel, G. C. (2016). *Time series analysis: Forecasting and control*. Wiley.
- [3] Carvour, M. L., Smith, L. M., & Heavenrich, J. (2018). Bayesian modeling in environmental health research. *Environmental Health*, 17(1), 1–10.
- [4] Chatfield, C. (2004). *The analysis of time series: An introduction*. Chapman and Hall/CRC.
- [5] Cameletti, M., Lindgren, F., Simpson, D., & Rue, H. (2013). Spatio-temporal modeling of particulate matter concentration through the SPDE approach. *AStA Advances in Statistical Analysis*, 97(2), 109–131.
- [6] Cressie, N., & Wikle, C. K. (2011). *Statistics for spatio-temporal data*. Wiley.
- [7] Departamento Administrativo Nacional de Estadística (DANE). (2023). *Proyecciones de población por localidad, Bogotá D.C. 2018–2035*. Bogotá, Colombia.
- [8] Ebi, K. L., & McGregor, G. R. (2008). Climate change, tropospheric ozone and particulate matter, and health impacts. *Environmental Health Perspectives*, 116(11), 1449–1455. <https://ehp.niehs.nih.gov/doi/10.1289/ehp.11463>
- [9] Environmental Protection Agency (EPA). (2024). *BenMAP User Manual v0.5*. United States Environmental Protection Agency. <https://www.epa.gov/benmap>

- [10] U.S. EPA. (2023). *BenMAP-CE User Manual v1.5.8*. United States Environmental Protection Agency. <https://www.epa.gov/benmap>
- [11] U.S. EPA. (2024). *Estimating PM_{2.5}- and ozone-attributable health benefits: Technical Support Document (TSD)*. EPA Office of Air Quality Planning and Standards.
- [12] Fiore, A. M., Naik, V., & Leibensperger, E. M. (2015). Air quality and climate connections. *Journal of the Air & Waste Management Association*, 65(6), 645–685.
- [13] Gelman, A., Carlin, J., Stern, H., Dunson, D., Vehtari, A., & Rubin, D. (2014). *Bayesian data analysis* (3rd ed.). CRC Press.
- [14] Gelman, A., & Hill, J. (2007). *Data analysis using regression and multilevel/hierarchical models*. Cambridge University Press.
- [15] Gelfand, A. E., Diggle, P. J., Fuentes, M., & Guttorp, P. (2010). *Handbook of spatial statistics*. CRC Press.
- [16] González, Y., & Pabón, J. D. (2019). Evaluación del impacto del cambio climático en la salud en Colombia. *Revista Salud Pública*, 21(6), 724–730.
- [17] Hoffmann, B., et al. (2021). WHO Air Quality Guidelines 2021 – Aiming for Healthier Air for All: A Joint Statement. *International Journal of Public Health*, 66, 1604465. <https://www.ssph-journal.org/journals/international-journal-of-public-health/articles/10.3389/ijph.2021.1604465/full>
- [18] Imam, R., et al. (2024). Air quality monitoring using statistical learning models for sustainable environment. *Intelligent Systems with Applications*, 22, 200333. <https://www.sciencedirect.com/science/article/pii/S2667305324000097?via%3Dihub>
- [19] Intergovernmental Panel on Climate Change (IPCC). (2022). *Climate change 2022: Impacts, adaptation and vulnerability*. Cambridge University Press. <https://www.ipcc.ch/report/ar6/wg2/>

- [20] Jacob, D. J., & Winner, D. A. (2009). Effect of climate change on air quality. *Atmospheric Environment*, 43(1), 51–63. <https://www.sciencedirect.com/science/article/abs/pii/S1352231008008571?via%3Dihub>
- [21] Lee, D., Rushworth, A., & Sahu, S. K. (2015). A Bayesian localized conditional autoregressive model for estimating the health effects of air pollution. *Biometrics*, 71(3), 780–791.
- [22] Manisalidis, I., Stavropoulou, E., Stavropoulos, A., & Bezirtzoglou, E. (2020). Environmental and health impacts of air pollution: A review. *Frontiers in Public Health*, 8, 14.
- [23] Ministerio de Ambiente y Desarrollo Sostenible. (2017). *Resolución 2254 de 2017: Por la cual se adoptan las normas de calidad del aire en Colombia*.
- [24] Ortiz-Durán, E. Y., & Rojas-Roa, N. Y. (2013). Estimación de los beneficios económicos en salud asociados a la reducción de PM10 en Bogotá. *Revista de Salud Pública*, 15(1), 90–102.
- [25] Pope, C. A., & Dockery, D. W. (2006). Health effects of fine particulate air pollution: Lines that connect. *Journal of the Air & Waste Management Association*, 56(6), 709–742.
- [26] Ramírez, O. L., et al. (2013). Estimación de los beneficios económicos en la salud al reducir PM10 en Bogotá. *Revista de Salud Pública*, 15(3), 379–391.
- [27] Rodríguez-Villamizar, L. A., et al. (2018). Síntomas respiratorios asociados con la exposición a la contaminación del aire en cinco localidades de Bogotá, 2008–2011: Estudio en una cohorte dinámica. *Biomédica*, 38(3), 347–356.
- [28] Romero-Lankao, P., Qin, H., & Borbor-Cordova, M. (2013). Exploration of health risks related to air pollution and climate change in Latin America: A critical review. *Environment International*, 52, 157–167.

- [29] Sacks, J. D., Fann, N., & Hubbell, B. (2018). Using BenMAP-CE to estimate the health benefits of air quality improvements. *Air Quality, Atmosphere & Health*, 11(5), 553–563.
- [30] Safari, Z., Fouladi-Fard, R., Vahedian, M., Mahmoudian, M. H., Rahbar, A., & Fiore, M. (2022). Health impact assessment and evaluation of economic costs attributed to PM_{2.5} air pollution using BenMAP-CE. *International Journal of Biometeorology*, 66, 1891–1902. <https://link.springer.com/article/10.1007/s00484-022-02330-1>
- [31] Saltelli, A., et al. (2008). *Global sensitivity analysis: The primer*. Wiley.
- [32] Tagaris, E., et al. (2010). Sensitivity of air pollution-induced premature mortality to precursor emissions under the influence of climate change. *International Journal of Environmental Research and Public Health*, 7(5), 2222–2237. <https://www.mdpi.com/1660-4601/7/5/2222>
- [33] Vehtari, A., Gelman, A., & Gabry, J. (2017). Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC. *Statistics and Computing*, 27(5), 1413–1432.
- [34] World Health Organization (WHO). (2021). *WHO global air quality guidelines: Particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. <https://www.who.int/publications/i/item/9789240034228>
- [35] World Bank & Institute for Health Metrics and Evaluation (IHME). (2016). *The cost of air pollution: Strengthening the economic case for action*. World Bank. <https://openknowledge.worldbank.org/entities/publication/cf3cfda2-6232-5f57-9979-dacb8aa5a302>
- [36] Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.
- [37] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning*. Springer.
- [38] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning with applications in R* (2nd ed.). Springer.
- [39] Shumway, R. H., & Stoffer, D. S. (2017). *Time series analysis and its applications*. Springer.

- [40] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [41] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- [42] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533–536.
- [43] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [44] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.
- [45] Departamento Administrativo Nacional de Estadística – DANE. (2025). *Proyecciones y retroproyecciones de población municipal para el periodo 1985–2017 y 2018–2042 con base en el CNPV 2018*. Bogotá D.C.: DANE. <https://www.dane.gov.co>
- [46] Secretaría Distrital de Ambiente (SDA). (2024). *Red de Monitoreo de Calidad del Aire de Bogotá (RMCAB) – Datos horarios de contaminantes criterio 2020–2024*. Bogotá D.C.: Alcaldía Mayor de Bogotá. <https://www.ambientebogota.gov.co/>
- [47] Agencia de Protección Ambiental de los Estados Unidos – EPA. (2021). *Environmental Benefits Mapping and Analysis Program – Community Edition (BenMAP-CE) User’s Manual*. Washington, D.C.: U.S. Environmental Protection Agency. <https://www.epa.gov/benmap>
- [48] Instituto de Hidrología, Meteorología y Estudios Ambientales – IDEAM. (2023). *Informe Nacional de Calidad del Aire 2022*. Bogotá D.C.: Ministerio de Ambiente y Desarrollo Sostenible.
- [49] Rodríguez, S., & Rincón, D. (2020). Modelación de contaminantes atmosféricos en Bogotá utilizando herramientas estadísticas y satelitales. *Revista de Ingeniería Universidad de los Andes*, 51(1), 57–73. <https://doi.org/10.16924/riua.v51i1.834>

- [50] Gouveia, N., & Fletcher, T. (2000). Time series analysis of air pollution and mortality: Effects by cause, age and socioeconomic status. *Journal of Epidemiology & Community Health*, 54(10), 750–755. <https://doi.org/10.1136/jech.54.10.750>
- [51] Hubbell, B. J., Hallberg, A., McCubbin, D. R., & Post, E. (2005). Health-related benefits of attaining the 8-hr ozone standard. *Environmental Health Perspectives*, 113(1), 73–82. <https://doi.org/10.1289/ehp.7186>
- [52] U.S. Environmental Protection Agency (EPA). (2017). *Guidelines for Human Exposure Assessment (EPA/100/B-19/001)*. Washington, D.C.: Office of Research and Development, U.S. Environmental Protection Agency. <https://www.epa.gov/risk/guidelines-human-exposure-assessment>
- [53] Intergovernmental Panel on Climate Change (IPCC). (2021). *Climate Change 2021: The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the IPCC*. Cambridge, United Kingdom: Cambridge University Press. <https://www.ipcc.ch/report/ar6/wg1/>
- [54] Bivand, R. S., Pebesma, E., & Gómez-Rubio, V. (2013). *Applied Spatial Data Analysis with R* (2nd ed.). New York, NY: Springer. <https://doi.org/10.1007/978-1-4614-7618-4>
- [55] Morgan, M. G., & Henrion, M. (1990). *Uncertainty: A Guide to Dealing with Uncertainty in Quantitative Risk and Policy Analysis*. Cambridge, United Kingdom: Cambridge University Press.
- [56] Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3rd ed.). Chapman and Hall/CRC.
- [57] Sahu, S. K. (2011). Hierarchical Bayesian models for space–time air pollution data. *Statistical Methodology*, 8(5), 473–494.